

1. 下面对强化学习、监督学习和深度卷积神经网络学习的描述正确的是 (A)。

- A. 评估学习方式、有标注信息学习方式、端到端学习方式
- B. 有标注信息学习方式、端到端学习方式、端到端学习方式
- C. 评估学习方式、端到端学习方式、端到端学习方式
- D. 无标注学习、有标注信息学习方式、端到端学习方式

强化学习是智能体通过与环境交互, 根据获得的奖励或惩罚来学习改进策略, 是一种评估学习方式; 监督学习利用一组已知输入和对应的期望输出的数据集来训练模型, 因此是有标注信息学习方式; 深度卷积神经网络直接从原始输入学习特征并完成任务, 是端到端学习方式。

2. 在强化学习中, 以下两个步骤的迭代可学习得到最佳策略的是 (D)。

- A. 价值函数计算与动作 - 价值函数计算
- B. 动态规划与 Q -learning
- C. 贪心策略优化与 Q -learning
- D. 策略优化与策略评估

通用策略迭代: 策略优化和策略评估交替进行

3. 在强化学习中, 以下机制的引入使得强化学习具备在利用与探索中寻求平衡的能力的是 (A)。

- A. ϵ -贪心策略
- B. 蒙特卡洛采样
- C. 动态规划
- D. 贝尔曼方程

ϵ -贪心策略: $(1-\epsilon)$ 概率选择当前估计价值最高的动作 —— 利用
 ϵ 概率随机选择一个动作 —— 探索

4. 与马尔可夫奖励过程相比, 马尔可夫决策过程引入的新元素是 (B)。

A. 反馈

B. 动作

C. 终止状态

D. 概率转移矩阵

MDP 包含状态集 S 、状态转移概率 P 、奖励函数 R 、折扣因子 γ

MDP 引入了动作集 A 。 $MDP = (S, A, P, R, \gamma)$

5. 根据本章内容, “在状态 s , 按照某个策略行动后在未来所获得回报值的期望” 这句话描述了状态 s 的 (B); “在状态 s , 按照某个策略采取动作 a 后在未来所获得回报值的期望” 这句话描述了状态 s 的 (C)。

A. 策略优化

B. 价值函数


C. 动作 - 价值函数

D. 采样函数

价值函数 $V_{\pi}(s)$: 在状态 s , 按策略 π 行动后的期望回报

动作-价值函数 $q_{\pi}(s, a)$: 在状态 s , 按策略 π , 执行动作 a 后的期望回报

6. 将图 6.2 所示的机器人寻路问题简化为题图 6.1 所示的 2×2 的网格, 假设有位于 s_1 位置的机器人拟从 s_1 这一初始位置向 s_4 这一目标位置移动。机器人每次只能向上或者向右移动一个方格, 到达目标位置 s_4 则会获得奖励且游戏终止。机器人在移动过程中如果越出方格 (s_d), 则会被惩罚且被损坏, 并且游戏终止。奖励值定义如下: 当 $S_{t+1} = s_4$ 时, 奖励值为 1; 当 $S_{t+1} = s_d$ 时, 惩罚值为 -1; 其他情况下奖励值为 0。若折扣因子 $\gamma = 0.99$, 智能体在 s_1 、 s_2 、 s_3 的策略都初始化为上, 终止状态 s_4 、 s_d 的价值函数定义为 0, 试通过联立贝尔曼方程给出状态 s_1 、 s_2 、 s_3 的价值函数。



题图 6.1 2×2 的机器人寻路问题

贝尔曼方程: $V_{\pi}(s) = R(s, \pi(s), s') + \gamma V_{\pi}(s')$

$$V_{\pi}(s_2) = R(s_2, \pi(s_2), s'_2) + \gamma V_{\pi}(s'_2) = R(s_2, \text{上}, s_4) + \gamma V_{\pi}(s_4) = 1 + 0.99 \times 0 = 1$$

$$V_{\pi}(s_3) = R(s_3, \pi(s_3), s'_3) + \gamma V_{\pi}(s'_3) = R(s_3, \text{上}, s_d) + \gamma V_{\pi}(s_d) = -1 + 0.99 \times 0 = -1$$

$$V_{\pi}(s_1) = R(s_1, \pi(s_1), s'_1) + \gamma V_{\pi}(s'_1) = R(s_1, \text{上}, s_3) + \gamma V_{\pi}(s_3) = 0 + (-1) \times 0.99 = -0.99$$

综上, $V_{\pi}(s_1) = -0.99$, $V_{\pi}(s_2) = 1$, $V_{\pi}(s_3) = -1$