

2025 年高教社杯全国大学生数学建模竞赛

摘要

（第 1 段）问题重述+简要思想：首先简要叙述所给问题的背景和动机，并分别分析每个小问题的特点（以下以三个问题为例）。根据这些特点说出自己的思想：针对于问题 1，采用。。。。。。的方法解决；针对问题 2 用。。。。。。的方法解决；针对问题 3 用。。。。。。的方法解决。

（第 2 段）模型建立及求解结果：介绍思想和模型：对于问题 1 我们首先建立了。。。。。。模型 I。首先利用。。。。。。，其次计算了。。。。。。，并借助。。。。。。数学算法和。。。。。。软件得出了。。。。。。结论。

（第 3 段）对于问题 2 我们用。。。。。。。

（第 4 段）对于问题 3 我们用。。。。。。。（模型的建立与求解结果的陈述中，思想、模型、软件和结果必须描述清晰，亮点详细说明需突出。针对不同问题可独立成段也可采用一段式仅用分号“；”分割，摘要只接受文字描述形式，不接受图表其他方式）

（第 5 段）优化结果及总结：在。。。。。。条件下，针对。。。。。。模型进行适当修改与优化，这种条件的改变可能来自你的一种猜想或建议。要注意合理性。此推广模型可以不深入研究，也可以没有具体结果。

注：字数 300~600 之间，需控制在一页；摘要中必须将具体方法、模型和所得结果写出来；摘要要求“总分总”，段开头可用“针对问题 1，针对问题 2，针对问题 3..”或者“首先，然后，其次，最后”等词语进行有逻辑的论述。摘要是重中之重，必须严格执行！

为实现精准产前筛查提供了科学、透明的解决方案。

一、问题重述

1.1 问题背景

无创产前检测(NIPT)是一项通过抽取孕妇外周血并分析母体血浆中来自胎儿的游离 DNA, 以期望尽早地识别胎儿染色体异常, 从而在早期评估胎儿的健康状况的技术。临床上常见的染色体非整倍体包括 21 号、18 号和 13 号三类, 分别对应唐氏综合征、爱德华氏综合征和帕陶氏综合征三种畸形胎儿的体征, 其判定依据是对应染色体游离片段的浓度有无异常。另一方面, 判定结果准不准确还跟性染色体浓度(即胎儿 X 或 Y 染色体在总片段中的比例)有着较大关系, 一般认为在怀孕期 10 到 25 周内测得出来的结果数据比较可靠, 且若男胎的 Y 染色体浓度达到或超过 4%, 女胎的 X 浓度无异常, 则 NIPT 结果可以被视为基本可信, 否则难以保证诊断质量。临床也强调 NIPT 筛查时点的重要性, 越早发现异常越利于进行即时的干预治疗。按风险可将检测时间划分为早期(孕周小于等于 12 周, 风险较低)、中期(孕周在 13 到 27 周, 风险较高)和晚期(孕周大于等于 28 周, 风险极高)。

在实际进行的观测显示出的结果来看, 男胎样本的 Y 染色体游离 DNA 片段的比例与孕周以及孕妇体质指数(BMI)存在显著关联。由于孕妇在年龄、体型、妊娠方式等方面存在个体差异, 简单采用统一时间点或粗略经验分组进行 NIPT, 准确性不佳, 可能导致某些人群的检测未能及时达标、错过诊疗窗口, 增加潜在风险。因此, 依据 BMI 等指标对孕妇进行合理细分, 并为每一组确定更合适的检测时点, 有望降低因 NIPT 时点选择不当带来的不确定性, 降低孕妇产下畸形胎儿的风险。

1.2 问题要求解读

附件给出了某地区孕妇的 NIPT 数据, 包括孕妇年龄、体型相关、妊娠方式、孕周、BMI、总段读数相关、染色体相关等数据。

问题一 建立回归模型, 刻画胎儿 Y 染色体游离 DNA 片段的比例随孕妇的孕周数和孕妇 BMI 以及其他因素的变化规律, 检验这些变量的显著性并进行模型的拟合效果的评价。

问题二 在只以孕妇 BMI 为分层依据的前提下, 以减低孕妇可能的潜在风险为目标, 题目主要有两个目标, 一是设计合理的男胎孕妇 BMI 分组, 二是为每一组确定最合适的 NIPT 采血时间点, 最后对检测时产生的误差对于结果的影响。

问题三 该问题在问题二的研究基础上, 在同时考虑孕妇的身高、体重、年龄、检测的误差以及胎儿 Y 染色体游离 DNA 片段的比例是否达标等更多因素的影响, 同样解决两个主要问题: 一是提出更精准的男胎孕妇 BMI 分组方案, 二是确定每组对应的 NIPT 采血时间点, 最后进行检测误差的相关分析。

问题四 考虑女胎样本异常的判定, 针对女胎样本, 整合 21 号、18 号以及 13 号染色体的非整倍体情况, 将其作为判定结果, 综合考虑 X 染色体信息、四种染色体的 Z 值和 GC 含量、测序读段比例与 BMI 等指标, 构建或制定用于判断染色体非整倍体的判别方法, 并评估该方法的灵敏性、特异性与在不同测序质量下的稳定性。

二、问题分析

2.2 总体性分析

2.2 问题一的分析

2.3 问题二的分析

考虑到我们最终的目的是为了通过 BMI 将孕妇分组并给出差异化的 NIPT 检测时间点，为临床诊断和治疗提供科学依据。因此简单的利用孕妇 BMI 本身的特性对孕妇群体进行划分的方案（如 K-means 聚类算法）是不够合理的。

因此，我们考虑使用目标驱动的决策树分类方案来对孕妇群体进行 BMI 的分组。

2.4 问题三的分析

2.5 问题四的分析

问题四的核心任务是，针对与男胎检测机制存在显著差异的女胎孕妇，构建一个能够精准、可靠地判定 21、18、13 号染色体非整倍体异常的科学方法。这不仅是一个常规的分类任务，更要求我们深入理解并解决女胎 NIPT 检测中特有的信号复杂性与不确定性，最终提出一个兼具高性能与临床可解释性的诊断方案。

三、模型假设

四、符号说明

对本文使用到的相关符号进行说明如下表：

符号	说明	单位
r	Pearson 相关系数	/
$C_{Y_{ij}}$	第 i 名孕妇第 j 次检测时的 Y 染色体浓度	/
β_0	LMM 的总体固定截距	/
β_1	BMI 对 Y 染色体浓度的固定效应系数	/
β_2	年龄对 Y 染色体浓度的固定效应系数	/
β_3	孕周对 Y 染色体浓度的固定效应系数	/
W_{ij}	第 i 名孕妇第 j 次检测时的孕周	周
A_{ij}	第 i 名孕妇第 j 次检测时的年龄	岁
B_{ij}	第 i 名孕妇第 j 次检测时的 BMI	/

b_i	LMM 中第 <i>i</i> 名孕妇的随机截距	/
$T_{k_{\min}}$	第 <i>k</i> 组孕妇的最佳 NIPT 检测时间	周
N_k	第 <i>k</i> 组孕妇的人数	人
$P_i(T)$	孕妇 <i>i</i> 在 <i>T</i> 时间检测下的达标概率	/
α	未达标概率可以接受的最大值	/

*其他未列出的符号会在正文中进行解释

五、总体数据预处理

5.2 异常值的处理 处理结果?

5.1.1 一致性交叉校验

对每一位受试孕妇，以已知身高与体重计算 BMI 指标：

$$BMI_2 = \frac{\text{weight}(kg)}{\text{height}(m)^2} \quad (1)$$

比较 BMI_2 与原始记录的 BMI_1 。如果 $|BMI_2 - BMI_1| > 0.01$ ，则判定该条记录为异常数据。然后，最常见的孕周计算方法是由末次月经时间确定的，所以本文以检测日期 t_1 和末次月经时间 t_2 计算推算孕周：

$$GA_{calc} = (t_1 - t_2) \quad (2)$$

GA_{record} 为附件表格中记录的孕妇本次检测时的孕周，当 $|GA_{calc} - GA_{record}| > 30$ 时判定为异常数据。

5.1.2 时间窗口筛选

在一般情况下，孕妇进行产前检测胎儿性染色体浓度的时间窗口是 10-25 周，认为在这个时间窗口进行的孕妇产前检测的数据才是可信任的，本研究选择将检测时间在 10-25 周以外的数据视为异常数据，进行剔除。

5.1.3 IQR 异常值识别

对于男胎孕妇样本，在剔除通过交叉校验判定为异常的记录后，使用 IQR 法进行异常值识别，选择 IQR 倍数为 1.5。对包括 B 孕妇 BMI，GC 含量,原始读段数，13 号染色体的 Z 值，18 号染色体的 Z 值，21 号染色体的 Z 值，X 染色体的 Z 值，X 染色体浓度，13 号染色体的 GC 含量，18 号染色体的 GC 含量，21 号染色体的 GC 含量，被过滤掉读段数的比例这些数据，计算数据的第一四分位数、第三四分位数 Q_1 ， Q_3 以及 $IQR = Q_3 - Q_1$ 。当 $X < Q_1 - 1.5IQR$ 或 $X > Q_3 + 1.5IQR$ 时，则将该条数据判定为异常。

5.3 缺失值的处理

为处理存在缺失的数据，

六、问题一的模型建立与求解

6.1 探索性数据分析

6.1.1 Pearson 相关系数

相关系数用于描述两组变量之间的相关程度，而 Pearson 相关系数用于度量两组数据的变量 a 和 b 之间的线性相关的程度，是两个变量的协方差与其标准差的乘积之比，计算公式为：

$$r = \frac{\sum_{i=1}^n (a_i - \bar{a})(b_i - \bar{b})}{\sqrt{\sum_{i=1}^n (a_i - \bar{a})^2 \sum_{i=1}^n (b_i - \bar{b})^2}} \quad (3)$$

其中 $\bar{a} = \sum_{i=1}^n a_i$ ， $\bar{b} = \sum_{i=1}^n b_i$ 。

在本质上，Pearson 相关系数归一化度量了协方差，因此结果的变化范围为 $[-1, 1]$ ， r 值为正值表示 a 和 b 之间的相关关系为正相关，即因变量随着自变量的增长而增长； r 值为负值表示 a 和 b 之间的相关关系为负相关，即因变量随着自变量的增长而减小； $|r| \geq 0.8$ ，就可以认为 a 和 b 之间的相关性极强； $0.6 \leq |r| < 0.8$ 之间，就可以认为相关性较强； $0.4 \leq |r| < 0.6$ ，就可以认为相关性较弱； $|r| < 0.4$ ，就可以认为相关性极弱或不存在相关性。

除了问题中提到的孕妇的孕周数和 BMI 指标之外，在查阅相关文献之后，我们根据医学临床经验分析出，孕妇的年龄也是评估孕妇孕情和胎儿生理健康状况的重要指标。因此，在模型构建阶段，我们将孕妇年龄也作为自变量纳入考量。

基于此，我们首先对于分析胎儿 Y 染色体浓度与孕妇的孕周数，BMI 指标和年龄因素之间的相关性，计算两两变量之间的 Pearson 相关系数，得到 Pearson 相关系数矩阵，来探索分析这些变量之间是否存在显著的线性相关性。

对于计算得到的 Pearson 相关系数矩阵，绘制热力图如图 1 所示。




图 1 相关性热力图

从图中可以直观看出 $|r| \leq 0.167$ ，表明胎儿 Y 染色体浓度与孕妇的孕周数和 BMI 指标以及年龄因素两两之间线性相关性极弱。由于 Pearson 相关系数描述的是线性相关性，当线性相关被否定时，变量之间可能还有其他相关的相关关系。若两个随机变量相互独立，则一定不相关；但是反过来，不相关不能推出相互独立

6.1.2 Spearman 相关系数

6.2 线性混合效应模型

6.2.1 模型选择的必要性分析

在进行完初步的探索性数据分析之后，我们发现单一的自变量与孕妇体内 Y 染色体浓度之间的线性相关性都不高。这说明，简单的双变量线性模型并不足以刻画因变量更为复杂的形成和决定机制。因此，我们排除选择一元线性模型，进一步考虑多元线性回归模型。

同时，我们注意到数据集中存在“对某些孕妇有多次采血多次检测或一次采血多次检测”的情况。这就导致了模型的数据并非是完全独立的，它们在“孕妇个体”这一角度存在关联性。这违背了传统线性回归模型在数据集上的独立性假设的要求。对此，我们首先考虑对同一个孕妇个体，通过选择最早或最晚时间，或者通过计算平均值来实现仅保留一条有效数据。但是，这样的数据简化策略存在很明显的缺点。首先对于孕妇个体而言，Y 染色体浓度随孕周的变化本身就是很宝贵的原数据，将其简化为一条数据可能会使个体内部变化趋势的信息丢失。其次，这种处理方法大幅减少了数据量，极有可能会对模型的求解造成很大的影响。

基于上述考量，我们最终选择了一种更为全面的统计模型——线性混合效应模型（Linear Mixed-Effects Model, LMM）来充分利用数据集中的纵向信息和重复测量数据。该模型通过引入随机效应来明确孕妇个体之间的差异性，同时利用固定效应来估计 BMI、孕周数、年龄等变量对全体样本的影响。通过这个模型，我们可以有效的解决数据的非独立性问题。

6.2.2 线性混合效应模型的构建

我们将 Y 染色体浓度设置为模型的因变量，将纳入考量范围的孕妇 BMI、孕周数、年龄作为固定效应。考虑到孕妇之间的个体差异，我们将孕妇代码作为分组变量，引入随机效应，建立了一个随机截距线性混合效应模型。其数学表达式如下：

$$C_{Y_{ij}} = (\beta_0 + b_i) + \beta_1 B_{ij} + \beta_2 A_{ij} + \beta_3 W_{ij} + \varepsilon_{ij} \quad (4)$$

其中： $C_{Y_{ij}}$ 表示第 i 名孕妇第 j 次检测时的 Y 染色体浓度， β_0 表示总体固定截距， b_i 表示第 i 名孕妇的随机截距， β_1 、 β_2 、 β_3 分别表示第 i 名孕妇第 j 次检测时的 BMI、年龄、孕周对 Y 染色体浓度的固定效应系数， B_{ij} 表示第 i 名孕妇第 j 次检测时的 BMI 值， A_{ij} 表示第 i 名孕妇第 j 次检测时的年龄， W_{ij} 表示第 i 名孕妇第 j 次检测时的孕周， ε_{ij} 表示随机误差项。

6.3 线性混合效应模型的求解与检验

6.3.1 线性混合方程

通过 Python 中的 statsmodels 库对模型进行拟合和求解，得到线性混合方程如下：

$$C_{Y_{ij}} = (0.0910 + b_i) - 0.0011B_{ij} - 0.0008A_{ij} + 0.0027W_{ij} + \varepsilon_{ij} \quad (5)$$

6.3.2 结果评估

对拟合的线性混合模型进行显著性检验，得到表 1 的统计结果

表 1 线性混合模型的评估

	<i>Coef.</i>	<i>Std.Err.</i>	<i>z</i>	$p > z $	[0.025	0.975]
Intercept	0.091	0.025	3.709	0.000	0.043	0.139
年龄	-0.001	0.000	-1.744	0.081	-0.002	0.000
检测孕周	0.003	0.000	15.790	0.000	0.002	0.003
孕妇 BMI	-0.001	0.001	-1.683	0.092	-0.002	0.000
Group Var	0.001	0.006				

表中： $Coef.$ 表示固定效应系数估计值； $Std.Err.$ 表示系数的标准误，衡量系数估计值的不确定性或者精确度； z 表示 z 统计量，系数除以标准误，用于检验系数是否为 0； $p > |z|$ 表示 p 值，若 $p < 0.05$ 认为自变量对因变量的影响显著；[0.025, 0.975] 为系数的 95% 置信区间，提供系数真实值可能存在的范围。

从显著性检验结果可以看出，检测孕周和孕妇 BMI 和 Y 染色体浓度有强相关性，

表 2 条件 R2 和边际 R2

度量	值	说明
----	---	----

边际 R^2	0.111595	由固定效应解释的方差比例
条件 R^2	0.782868	由固定效应和随机效应共同解释的方差比例

从表 2 中可以看出, 条件 R^2 远高于边际 R^2 , 这证明了考虑孕妇个体这一随机效应的正确性。

6.3.3 结果可视化

考虑到原方程是四维空间中的三维超平面, 不易进行可视化, 且年龄这一变量与 Y 染色体浓度(显著性检验)、孕妇 BMI(0.01 pearson)、检测孕周(0.01 pearson)的相关性均不强, 单独以孕妇 BMI 和检测孕周为固定效应, 进行模型的拟合, 结果方程中, 孕妇 BMI 和检测孕周的系数与方程(x)相同, 故..。图 2 是散点分布与拟合平面的三维视图。




图 2 散点分布与拟合平面

6.4 结果与分析

为了验证线性混合模型的优越性, 我们使用了传统的普通最小二乘法(OLS)拟合 Y 染色体浓度与孕妇 BMI、孕周数和年龄的回归方程。分别绘制线性混合效应模型和普通最小二乘法的残差图如图 3 所示。




图 3 LMM 和 OLS 残差分布对比

七、从上面的残差图可以看出，相比于忽略随机效应的传统 OLS 最小二乘法，线性混合效应模型的残差整体更优。问题二的模型建立与求解

7.1 基于目标驱动决策树的 BMI 划分方案

7.1.1 孕妇个体 Y 染色体浓度达标孕周预测


由于存在“某些孕妇有多次采血多次检测或一次采血多次检测”的情况，因此数据集中存在大量的纵向数据。同一个孕妇个体的不同检测数据具有逻辑上的强相关性，不能简单的作为独立数据处理。因此，我们首先对检测数据进行孕妇个体化处理，预测每一位孕妇个体的 Y 染色体浓度达标孕周时间的预测值。

注意到样本中孕妇个体的纵向数据之间具有不同特性，我们将其划分为三个子样本：首次检测时 Y 染色体浓度已达标组；检测过程中 Y 染色体浓度达标组；检测过程中 Y 染色体浓度始终未达标组。分别对三个子样本实行不同的预测方法：

1. 首次检测时 Y 染色体浓度已达标组：取首次检测时间作为达标孕周
2. 检测过程中 Y 染色体浓度达标组：取 Y 染色体浓度的、包含跨越点（Y 染色体浓度值等于 4%）的最长递增子序列，对其检测时间进行最小二乘线性回归拟合，并取达标浓度对应的时间作为达标孕周
3. 检测过程中 Y 染色体浓度始终未达标组：取最后一次检测时间作为达标孕周¹

7.1.2 目标驱动决策树的构建

为了对具有不同风险特征的孕妇群体进行有效划分，从而制定差异化的最优 NIPT 检测时间点分析，我们采用了目标驱动的决策树方法。以 Y 染色体浓度达标孕周预测值作为回归目标，孕妇个体的 BMI 值作为输入特征进行决策树划分。该方法会自动寻找最佳的 BMI 分割点以区分 Y 染色体浓度达标孕周时间差异较大的孕妇群体。




(图片名称)

我们遵循模型构建的奥姆卡剃刀原则，即在保证模型泛化能力的前提下，选择最简洁的模型。为了使决策树具有较高的解释性和良好的泛化能力，我们对决策树的关键参数进行约束。具体而言，我们进行了以下约束：

- 最大深度：我们将决策树的最大深度限制为 2，保证其叶节点数量最多为 $2^2=4$ 个。这避免了在我们的样本数据量较少的前提下，决策树对训练数据中噪声的过度拟合。
- 叶节点最小样本数：我们设定每个叶节点必须至少包含 15 个样本，保证了每个分组都具有一定的代表意义，避免决策树产生样本数量过少、统计学意义不足的分组。

7.1.3 决策树分组结果呈现



(决策树结果图)

基于决策树结果，我们将孕妇群体根据 BMI 值分为三组：

BMI 分组	样本数

7.2 生存分析：分组有效性验证与风险量化

为了检验我们上文提出的目标驱动决策树的分组方案的有效性，同时为后续的风险

优化决策方案提供精确的风险概率函数模型，我们采用生存分析（Survival Analysis）作为统计工具。

生存分析(Survival Analysis)是一个统计学领域，用于对事件发生时间的分布规律进行建模和分析预测，被广泛应用于医疗和公共卫生相关的研究中。其核心目标有三个：一是量化在某个时间点后，研究对象仍然未发生事件的概率，在本题中即是在某个时间点后，胎儿的 Y 染色体浓度仍未达标；二是分析影响因素，量化影响生存时间变量的影响程度；三是比较生存差异，当研究存在分组时，检验各组的生存曲线有无存在统计学差异。

在本题的研究背景下，我们将生存分析的关键概念进行如下对应：

- 事件 (Event)：胎儿的 Y 染色体浓度首次达到 4% 的阈值
- 时间 (Time)：孕周
- 生存 (Survival)：在孕周 t 时，Y 染色体浓度仍未达标的状态。
- 删失 (Censoring)：对于研究周期结束时（即最后一次检测时间）Y 染色体浓度仍未达标的孕妇，我们只能掌握其达标时间晚于该时间的信息。这类不完整的信息被称为“右删失数据”。生存分析能够科学且无偏的处理这类数据，这也是我们选择该方法的重要考虑因素。

7.2.1 Kaplan-Meier 生存曲线与分组有效性验证

采用非参数的 **Kaplan-Meier** 方法，分别对 7.1.3 节确定的三个 BMI 分组（低 BMI 组，中 BMI 组，高 BMI 组）进行生存分析和生存曲线的绘制，如图 X 所示。

图 5 不同分类下的 Y 染色体浓度未达标生存概率曲线(三分组)

图 X 展示了不同 BMI 分组下，Y 染色体浓度未达标的概率（即生存概率）随孕妇孕周数变化的过程。分析结果可知：

- 普遍规律：所有组别的生存曲线都呈现出单调递减趋势，表明随着孕周的增加，孕妇群体达标的比例在不断上升，与临床经验一致。
- 显著的组间差异：三条曲线呈现出明显的差异性。代表高 BMI 组的绿色曲线在整个观测周期内都几乎位于最上方，表明该组孕妇的 Y 染色体浓度达标速度最慢。而代表低 BMI 组的蓝色曲线和代表中 BMI 组的橙色曲线在 16 孕周之后也存在明显差异。

为了定量的判断我们的 BMI 分组是否具有统计学意义，我们采用了对数秩检验（Log-rank Test）。检验结果显示，三个组别之间的生存曲线存在统计学意义上的显著差异 ($p\text{-value} < 0.05$)。这个结果也证明了我们基于决策树得到的分组方案是合理的，能够有效将具有不同 NIPT 检测时间风险特征的孕妇群体区分开。

(pvalue 三线表)

7.2.2 Kaplan-Meier 生存曲线量化组别风险概率预测函数

在生存曲线的构建过程中，我们天然地得到了不同分组的一个概率计算引擎。我们假设孕妇数据样本具有一定的代表性，那么对于孕妇群体而言，在时间点的失败风险，可以量化为该群体在该时间点尚未达标的比例。这恰好就是我们生存分析中生存函数的定义。

因此，对于组别 k 的孕妇 i ，其在孕周 T 时检测失败的概率可以定义为：

(公式 1)

相应的，检测成功的概率可以定义为：

(公式 1.1)

7.3 优化模型确定 NIPT 最优时点

7.3.1 目标函数的构建

根据临床实践经验，我们将孕妇在 NIPT 检测中可能面临的总体潜在风险 R_{total} 抽象为两部分：

- 失败风险 (R_{fail})：由于 NIPT 检测时点过早，导致男胎孕妇体内 Y 染色体浓度不足而产生的风险。
- 延迟风险 (R_{delay})：由于检测失败导致检测时间推迟，进而导致确诊和干预治疗窗口期缩小的风险。

我们的目标是为每个 BMI 分组寻找一个最优的检测时点 T_k ，使得这两部分风险的加权总和最小。由此构建如下线性目标函数：

$$T_k^* = \min \{ \arg \min R_{total}(T_k) \}$$

$$s.t. R_{fail}(T) < \alpha$$

其中，总体潜在风险 R_{total} 的定义如下：

$$R_{total}(T_k) = w_1 R_{fail}(T_k) + w_2 R_{delay}^*(T_k) \quad (6)$$

其中， $T_{k_{min}}$ 表示第 k 组孕妇的最佳 NIPT 检测时间； T_{min} 和 T_{max} 是孕周时间的下限和上限值，根据临床经验，孕妇的孕期在 10 周到 25 周之间可以检测胎儿性染色体浓度，故取 $T_{min}=10$ ； w_1 和 w_2 是风险权重系数，代表我们对两部分风险的相对重视程度。在本研究中，我们认为两种风险的重要程度相当，故取 $w_1=w_2=0.5$ 。 α 是我们定义的最高可接受的失败风险概率，本研究中取 $\alpha=0.1$ 。

延迟风险随时间的推移而增加。实际临床经验表明，对于不健康的胎儿，早期发现（12 周以内）风险较低；中期发现（13—27 周）风险高；晚期发现（28 周以后）风险极高。为了刻画这种越往后越剧烈的趋势，我们构建了一个分段式线性函数 $R_{fail}(T)$ ：

$$R_{delay}(T) = \begin{cases} 1, & T \leq 12 \\ C_1(T - 12) + 1, & 12 < T \leq 27 \\ C_2(T - 27) + C_1(T - 12), & T > 27 \end{cases} \quad (7)$$

在 12 周前，我们设定风险为基准值 1；在 12 至 27 周的关键窗口期，风险以斜率 C_1 线性增长。在 27 周后，风险以更陡峭的斜率 C_2 线性增长，体现了晚期风险的急剧恶化。根据临床重要性，在本研究中我们设定 $C_1=1$ ， $C_2=2$ ，以确保模型对延迟风险有足够的敏感性。

考虑到 R_{fail} 是一个概率函数，其值域为 $[0, 1]$ 。为了使两部分风险的量化值的量纲一致，我们对延迟风险函数进行最大最小归一化处理，保证其值域同样为 $[0, 1]$ 。

$$R_{delay}^* = \frac{R_{delay} - \min(R_{delay})}{\max(R_{delay}) - \min(R_{delay})} \quad (8)$$

7.3.2 模型的求解

由于构建的目标函数 R_{total} 是关于一维变量 T_k 的函数，我们采用网格搜索（Grid Search）的方式求解。具体而言，我们在 $[10, 25]$ 的可行域内，以 0.1 周为步长，搜索满足约束条件 $R_{fail}(T) < \alpha$ 的、使得 R_{total} 值最小化的 T_k 。

7.3.3 结果分析

(结果图)

BMI 区间	NIPT 最佳时点
$BMI \leq 31.82$	17.1
$31.82 < BMI \leq 33.82$	23.3
$BMI > 33.82$	23.7

(1) 第一组 $BMI \leq 31.82$ ，最佳 NIPT 时点 17.1 周

这部分孕妇的 BMI 较低，血液中胎儿 Y 染色体浓度相对较高，因此可以在相早期就达到可以获得可靠结果的 Y 染色体浓度阈值，可以在 17.1 周左右进行 NIPT，尽早获得结果。

(2) 第二组 $31.82 < BMI \leq 33.82$ ，最佳 NIPT 时点 23.3 周

这部分孕妇的 BMI 适中，血液中积累胎儿 Y 染色体浓度相对于第一组较慢，为了确保 NIPT 检测准确性，需要等待一段时间，在 23.3 周左右进行 NIPT。

(3) 第三组 $BMI > 33.82$ ，最佳 NIPT 时点 23.7 周

这部分孕妇的 BMI 较高，血液中胎儿 DNA 浓度最低，积累最慢，可以将 NIPT 时点推至 23.7 周，以获得较为准确的检测结果。

总体而言，对于 BMI 值较高的孕妇群体来说，其检测失败风险函数下降的相对会更缓慢，因此模型更倾向于选择一个较晚的时间点，以提高部分延迟风险为代价，获得失败风险的显著降低；而对于低 BMI 组的孕妇群体来说，其检测失败风险函数下降的相对较快，因此模型能够选择一个较早的时间点，在失败风险已经进入可接受的范围是，来进一步获得更低的延迟风险。

7.4 检测误差影响分析（灵敏度分析）

八、问题三的模型建立与求解

8.1 Cox 比例风险回归模型

在问题二中，我们通过 **Kaplan-Meier** 方法计算出不同 BMI 组别的生存曲线，量化了组内孕妇体内 Y 染色体浓度未达标概率随孕期的变化。但是该方法是无参数的，无法进一步在同一组内衡量其他因素（比如身高、体重、年龄）对 Y 染色体浓度未达标概率的影响。因此，基于综合考虑多种因素的目标，我们引入了 Cox 比例风险回归模型。

Cox 比例风险回归模型是一种半参数回归模型。该模型以生存时间和生存结局共同构成因变量，可以引入多种因素作为协变量，同时衡量多因素对生存期的影响。由于其能分析带有截尾生存时间的资料，且不要求估计资料的生存分布类型，因此在医学研究中得到广泛推广和应用。

8.1.1 模型的构建

我们以所有男胎孕妇（数据预处理之后）的生存数据作为模型的训练集。孕妇的 Y 染色体浓度达标孕周时间的预测值处理方式与问题二相同。

模型的设定如下：

- 因变量：由最后一次检测时间和 Y 染色体浓度是否达标共同定义的生存结果

- 协变量：经过对多个变量的共线性检验，我们最终选定孕妇的身高、体重、年龄、GC 含量作为模型的协变量

模型的数学形式如下：

$$h(T|\mathbf{x}_i) = h_0(T)e^{\beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4}}$$

其中 $\mathbf{x}_i = [x_{i1}, x_{i2}, x_{i3}, x_{i4}]$ 是孕妇 i 的特征向量， $x_{i1}, x_{i2}, x_{i3}, x_{i4}$ 分别表示孕妇 i 的身高、体重、年龄和 GC 值， $h_0(T)$ 是基准风险率， $\beta_1, \beta_2, \beta_3, \beta_4$ 表示模型学习到的回归系数， $h(T|\mathbf{x}_i)$ 是具有特征向量 $\mathbf{x}_i$ 的孕妇 i 在孕期 T 的风险率。（对齐）

8.1.2 模型结果分析

（显著性分析结果图）

分析

而回归系数 β 则量化了每个生理指标对这一概率的推动或抑制作用。在拟合模型前，我们对所有连续型协变量进行了标准化处理，以消除量纲影响，确保回归系数的可比性。

8.1.3 模型量化个体风险概率预测函数

基于 Cox 比例风险回归模型，我们成功得到了每一组内，具有特征向量 X_i 的孕妇 i 在孕周 T 的风险率，也就是瞬时达标概率 $h(\cdot)$ 。与问题二的思路相同，我们仍然要得到具有特征向量 X_i 的孕妇 i 在孕周 T 的 Y 染色体浓度达标或者未达标概率，也就是生存函数。

在 Cox 模型构建时，我们已经建立了瞬时概率的模型：

$$h(T|\mathbf{x}_i) = h_0(T)e^{\beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4}}$$

然后，计算累计风险函数：

$$H(T|\mathbf{x}_i) = \int_0^T h(u|\mathbf{x}_i) du$$

最后，得到生存函数：

$$S(T|\mathbf{x}_i) = e^{-H(T|\mathbf{x}_i)}$$

同样的，对于孕妇群体而言，在时间点的失败风险，可以量化为该群体在该时间点尚未达标的比例。因此，对于组别 k 的孕妇 i ，其在孕周 T 时检测失败的概率可以定义为：

$$P_i(fail|T) = S(T|\mathbf{x}_i)$$

其在孕周 T 时检测成功的概率可以定义为：

$$P_i(succeed|T) = 1 - S(T|\mathbf{x}_i)$$

8.2 多因素考量下的风险决策模型

8.2.1 分组策略的继承

在问题二中，我们通过目标导向的决策树将孕妇划分为低中高 BMI 三组。在问题三中，我们决定沿用问题二的 BMI 划分框架。这一决定是基于以下考量的：

首先，BMI 作为临床上影响胎儿 Y 染色体浓度的最早达标时间的主要因素，将其作为宏观的分组指标，便于实际的临床应用，也能使我们的策略对临床医生具有清晰的、

可执行的实施。

其次，沿用问题二的分组，能够控制宏观变量，进而在组内通过综合考量其他多种因素，实现个性化、差异化的调节，使 Cox 模型的应用更具有策略优化结果上的可比性。

我们的核心思想是实现从宏观分层诊断到精准化诊疗的深化过程。我们并非忽略其他因素，而是将它们的作用聚焦到更精细的组内概率差异化上。即在同一个 BMI 分组内部，具有不同特征向量的孕妇，其风险曲线将由我们的 Cox 模型精确地区分开来。

8.2.2 目标函数

我们继续沿用期望风险最小化的目标函数：

$$T_k^* = \min \{ \arg \min R_{total}(T_k) \}$$

$$s.t. R_{fail}(T) < \alpha$$

总体潜在风险函数的定义与参数的取值与问题二保持一致：

$$R_{total}(T_k) = w_1 R_{fail}(T_k) + w_2 R_{delay}^*(T_k)$$

但是与问题二不同的是，失败风险函数的计算由组内群体平均值升级为了由 Cox 模型得出的个体化预测值。升级后的失败风险项我们定义为组内所有个体失败概率的算术平均值：

$$R_{fail}(T) = \frac{1}{N_k} \sum_{i \in G_k} S_i(T_k | \mathbf{x}_i)$$

这个函数说明，在衡量一个分组的平均达标失败风险时，我们不再单纯的使用一条通用的生存曲线，而是根据组内每一位孕妇的核心特征，从 Cox 模型估计出其个性化的生存曲线，再进行汇总。这使得我们的风险评估策略的颗粒度大大提高，而这也是我们采用 Cox 比例风险回归模型的初衷。

8.2.3 模型求解

同样的，由于目标函数 R_{total} 是关于一维变量 T_k 的函数，我们依旧采用网格搜索（Grid Search）的方式，在【10,25】的可行域内，以 0.1 周为步长，搜索满足约束条件的、使得 R_{total} 值最小化的 T_k 。

得到的结果如下所示：

()

8.3 与问题二的对比分析

为了证明引入多因素的有效性，量化引入多因素对于决策优化的影响，我们对问题三与问题二求得的策略结果进行对比分析：

()

8.4 检测误差影响分析（灵敏度分析）

九、问题四的模型建立与求解

9.1 探索性数据分析: Z 值在不同性别中的诊断能力差异

Z 值作为一种标准化的统计量，能够将染色体的相对测序读段数转化为其偏离正常群体均值的标准差倍数。查阅医学和生物学相关文献资料发现，Z 值很可能是染色体异

常的一个重要判定因素。例如，当 13 号染色体异常（如三倍体或单倍体）时，13 号染色体的 Z 值绝对值很可能超过 3。同时，通过初步的手动分析，我们发现在男胎孕妇群体中，若某条染色体异常，其对应的 Z 值绝对值偏高的概率会更大一些。基于这个发现，我们尝试对比男胎和女胎中正常样本和异常样本的三种染色体的 Z 值和 GC 含量分布。

（）
结果显示，在男胎孕妇群体中，。。。但是在女胎孕妇中。。。 （显著重叠，区分度大幅下降）
但是，我们也有意外发现。。。 （GC 含量在女胎孕妇群体中反而有比较明显的区分度）
（尝试解读？）

9.2 数据预处理与特征工程

9.2.1 数据预处理

（1）数据清洗与缺失值填充

（）（要说明最后有几个正常几个异常）
（2）SMORE 过采样：由于样本出现严重的类别不平衡问题，我们使用 SMORE 技术对异常样本进行过采样处理。理论上这会给模型带来更好的学习环境。
（3）数据标准化：我们对所有 15 个特征进行标准化处理，使其服从标准正态分布。这样可以消除特征之间不同量纲造成的影响。

9.2.2 GC 含量异常处理的考量

理论上来说，正常 GC 含量的范围是 40% ~ 60%。异常的 GC 含量可能会对测序质量有影响。但是，我们经过 GC 含量数据分布分析后，发现本数据集中的 GC 含量普遍集中于 0.4 附近范围，且有超过三分之一的样本位于【0.39,0.4】，如果直接依据 0.4 为划分点对数据进行清洗，可能会造成巨大的信息损失。进一步查阅文献（论文引用？），发现临床上更宽的 GC 含量值也是可接受的。因此，我们认为这可能是本次研究样本中的合理特征。因此，我们决定保留这些样本，将 GC 含量作为一个特征送入模型进行学习。

9.2.3 样本筛选和标签定义

经过数据预处理后，我们得到本次研究的所有女胎样本数据共。。。例。基于此我们对目标变量进行定义。考虑到 NIPT 筛查的首要任务是识别出任何染色体异常，以及本研究中异常样本数量过少的问题，我们将问题简化为二分类问题。对于样本个体，只要其染色体非整倍体检测异常，我们就将其定义为异常（ $y=1$ ），否则定义为正常（ $y=0$ ）。

处理过后，数据中包含正常样本。。。，异常样本。。。，依然存在显著的类别不均衡问题。

9.3 多模型对比与最优选择

9.3.1 k 折交叉验证方法和高召回率优先原则

在模型的训练与测试中，我们采用 5 折交叉验证的方式，对模型进行训练和评估。并计算最终模型的准确率、精确率、召回率和 F1-score。在这些评估指标上，我们重点关注模型的召回率。这是因为在临床诊断中，漏诊（假阴性）的后果要比误诊（假阳性）

严重的多。因此，作为 NIPT 检测模型，我们必须将尽可能多的筛查出异常个体为首要目标。

9.3.2 模型性能对比分析与最优模型选择

(图)

(分析召回率，auc 值等)

基于我们对召回率的极度优先原则，以及综合考量准确率、AUC 值等因素，我们最终选择逻辑回归模型作为女胎异常判定的模型。

Logistic 回归算法(Logistic Regression, LR)是一种基于 Sigmoid 函数的分类算法。其目标是找到一条直线或者超平面对数据集尽可能地分类，在线性回归的基础上加入了 Sigmoid 函数，将输出的结果转化为了一个介于 0 到 1 的值。Sigmoid 函数的表达式是：

$$y(z) = \frac{1}{1 + e^{-z}} \quad (9)$$

其中， $z = w^T x$ ，实质是 Logistic 回归要找的划分类别的超平面， w 是权重， x 是特征向量， $y(z)$ 输出的值实质是判断事件发生的概率。

Logistic 回归使用对数损失作为损失函数，表达式为：

$$L = -y \log \hat{y} + (1 - y) \log (1 - \hat{y}) \quad (10)$$

同时，逻辑回归模型作为一个“白箱”模型，其相对简单的结构也为我们对于各项特征重要性的解读和判定方法的量化提供了良好的基础。

9.4 基于逻辑回归的透明化判定方法

9.4.1 模型系数解读

(图)

分析

9.4.2 判定方法的量化

$$Score = \sum_{i=1}^{15} \beta_i \cdot x'_i + \beta_0$$

其中， x'_i 是经过标准化处理后的各项输入特征指标， β_i 是模型学习到的第 i 项指标的对应权重， β_0 是截距项(0.0162)。当 $Score$ 大于判别阈值 0 时，即可判定为高风险，推荐进行下一步的确诊性 NIPT。

这个判定方法的核心优势在于，我们不再局限于使用某个单一因素做阈值上的判断，而是综合评估以三类染色体 GC 含量为代表的多维度因素，给出一个更合理的，召回率较高的模型，且具有极高的可解释性。

十、模型的评价

10.1 模型的优点

10.2 模型的缺点

10.3 模型的改进方向

十一、参考文献

姜丰. Pearson 相关系数评价混合工质与纳米流体换热特性的应用研究[D]. 天津:天津大学,2017. DOI:10.7666/d.D01649099.

薛莹,丁洁,贺权泽,等. 孕妇年龄、孕周及体重指数对孕妇外周血中胎儿游离 DNA 比例的影响[J]. 中国产前诊断杂志(电子版),2017,9(3):5-10. DOI:10.13470/j.cnki.cjpd.2017.03.002.

张豪. 基于线性混合效应的结构脑影像分析及分类研究[D]. 山西:太原理工大学,2019.

甘郑宇. 基于多模态的癌症生存分析研究[D]. 黑龙江:哈尔滨工业大学,2024.

王楠. 基于差分隐私与逻辑回归优化模型的乳腺癌分类预测[D]. 湖北:湖北工业大学,2024.

郭亚亚. 溶血对基于高通量测序技术的无创产前检测质控指标和结果的影响[D]. 河南:郑州大学,2022.

附录 A 支撑材料文件列表

文件名	类型	简介
-----	----	----

附录 B 程序代码