

16.5 Consider the relations $r_1(A, B, C)$, $r_2(C, D, E)$, and $r_3(E, F)$, with primary keys A , C , and E , respectively. Assume that r_1 has 1000 tuples, r_2 has 1500 tuples, and r_3 has 750 tuples. Estimate the size of $r_1 \bowtie r_2 \bowtie r_3$, and give an efficient strategy for computing the join.

解: $r_1(\underline{A}, B, C)$, 1000个元组

$r_2(\underline{C}, D, E)$, 1500个元组

$r_3(\underline{E}, F)$, 750个元组

① 估计 $r_1 \bowtie r_2 \bowtie r_3$ 的大小

∵ r_1, r_2 有共同属性 C , 且 C 为 r_2 的主键, r_2 中每个 C 值是唯一的

∴ $V(r_1, C) \leq 1000$, $V(r_2, C) = 1500$

$$|r_1 \bowtie r_2| \approx \frac{|r_1| \cdot |r_2|}{\max(V(r_1, C), V(r_2, C))} = \frac{1000 \times 1500}{1500} = 1000$$

中间结果记为 $\text{Tmp}(A, B, C, D, E)$

同理, Tmp, r_3 有共同属性 E , 且 E 为 r_3 的主键

$V(r_3, E) = 750$, $V(\text{Tmp}, E) \leq 750$

$$|\text{Tmp} \bowtie r_3| \approx \frac{|\text{Tmp}| \cdot |r_3|}{\max(V(r_3, E), V(\text{Tmp}, E))} = 1000$$

$$\therefore |r_1 \bowtie r_2 \bowtie r_3| \approx 1000$$

② 高效的连接策略

一共三种连接方式

i) $(r_1 \bowtie r_2) \bowtie r_3$

中间结果Tmp的大小为1000

ii) $r_1 \bowtie (r_2 \bowtie r_3)$

r_3, r_2 有共同属性E, 且E为 r_3 的主键,

r_3 中每个E值是唯一的

$$V(r_3, E) = 750, \quad V(r_2, E) \leq 750$$

$$|r_2 \bowtie r_3| \approx \frac{|r_2| \cdot |r_3|}{\max(V(r_3, E), V(r_2, E))} = 1500$$

中间结果大小估计为1500

iii) $(r_1 \bowtie r_3) \bowtie r_2$

r_1 和 r_3 没有共同属性,

$$|r_1 \bowtie r_3| = |r_1 \times r_3| = |r_1| \cdot |r_3| = 750000$$

∴ 采用 $(r_1 \bowtie r_2) \bowtie r_3$ 更加高效

③ 连接算法

可以采用哈希表的方式

计算 $r_1 \bowtie r_2$ 时, 选择 r_1 在连接属性 C 上建立哈希表; 扫描 r_2 的每个元组, 使用其 C 值探测 r_1 的哈希表, 如果找到匹配就合并元组并输出到 Tmp ;

$Tmp \bowtie r_3$ 同理, 选择 r_3 在连接属性 E 上建立哈希表; 扫描 Tmp 的每个元组, 使用其 E 值探测 r_3 的哈希表, 如果找到匹配就合并元组并输出到最终结果.