



移动设备价格预测： 算法、数据与几何的博弈

一项关于随机森林、支持向量机与K近邻的深度对比研究


性能对比简析



支持向量机
(SVM)




随机森林
(Random Forest)



关键洞察：算法效能与
数据分布的几何关系

不同算法对高维数据空间的适应性各异，几何结构的理解是
预测精准度的核心。

随机森林
(Random Forest)



K近邻
(KNN)




目标：构建智能定价模型， 破解硬件与价格的映射密码

业务场景

手机制造商“Bob”需要一个数据驱动的模式，根据硬件特性预测其四个价格区间（0: 低成本，1: 中等成本，2: 高成本，3: 超高成本），以在竞争激烈的市场中进行精准定位。

任务定义

这是一个典型的监督学习多分类任务。我们的目标不是预测具体价格（回归），而是判断设备所属的价格等级。




20个特征，2000个样本，和一个完美平衡的战场

数据集规模

包含2000条手机样本数据，每条数据由20个特征描述，如RAM、电池容量、屏幕分辨率等。

关键特性：完美平衡

目标变量`price\_range`在四个类别上的分布完全均匀，各占25%（500个样本）。



Implication

这种平衡性消除了类别不平衡可能带来的预测偏见，使我们能够直接使用**准确率 (Accuracy)**作为核心评估指标，而无需担心“准确率悖论”。

唯一的线索：RAM与价格存在惊人的强线性关系

	battery_power	blue	clock_speed	dual_sim	fc	four_g	int_memory	m_dep	mobile_wt	n_cores	pc	px_height	px_width	ram	sc_h	sc_w	talk_time	three_g	touch_screen	wifi	price_range
battery_power	1	0.30	0.31	0.11	-0.03	0.13	0.18	-0.51	0.20	0.15	-0.18	0.27	0.36	0.82	0.29	0.17	-0.23	0.20	0.31	-0.31	0.82
blue	0.07	1	0.07	-0.15	-0.03	0.15	0.01	-0.03	0.24	0.17	-0.23	0.23	0.38	0.91	0.17	0.21	-0.13	-0.23	0.28	-0.98	0.91
clock_speed	0.10	0.20	1	0.00	0.23	0.23	0.28	-0.02	0.30	0.21	-0.03	0.67	0.38	0.99	0.29	0.24	0.23	0.31	0.21	-0.14	0.78
dual_sim	-0.18	0.28	0.00	1	0.08	0.25	0.15	-0.13	0.19	0.22	0.21	0.31	0.31	0.65	0.22	0.29	0.32	0.72	0.31	-0.14	0.85
fc	-0.12	-0.03	0.19	0.10	1	0.59	0.25	0.25	0.30	0.16	-0.24	0.67	0.38	0.93	0.23	0.28	-0.14	0.34	0.31	0.13	0.85
four_g	-0.11	0.25	0.23	0.13	0.00	1	0.78	0.25	0.42	0.21	0.24	0.32	0.76	0.87	0.23	0.23	-0.26	0.25	0.74	-0.19	0.85
int_memory	0.15	0.15	0.53	0.25	0.26	0.30	1	0.08	0.37	0.16	0.15	0.05	0.08	0.88	0.22	0.24	0.13	0.20	0.21	0.15	0.93
m_dep	-0.86	-0.33	0.21	-0.13	-0.04	0.25	0.21	1	0.21	0.18	-0.21	-0.47	-0.17	0.90	-0.23	-0.28	-0.23	0.31	-0.06	-0.33	0.99
mobile_wt	-0.23	-0.21	-0.13	0.14	-0.35	0.16	0.20	0.00	1	0.10	-0.12	0.30	-0.15	0.76	0.12	0.20	0.22	0.21	0.18	0.20	0.76
n_cores	0.18	0.28	0.19	0.23	-0.03	0.13	0.20	0.00	0.16	1	0.18	0.29	0.73	0.73	0.17	0.17	-0.23	0.32	0.81	-0.26	0.70
pc	-0.76	-0.04	0.31	-0.03	-0.23	0.16	0.18	-0.33	0.19	0.18	1	0.72	0.75	0.63	0.18	0.21	-0.17	-0.36	0.38	-0.25	0.79
px_height	-0.31	-0.03	0.33	0.10	-0.37	0.18	0.20	0.07	0.16	0.20	-0.79	1	0.73	0.83	0.12	0.20	0.28	0.24	0.75	-0.05	0.85
px_width	-0.96	-0.09	-0.08	0.26	-0.29	0.19	-0.10	0.07	0.26	-0.30	-0.09	0.79	1	0.87	0.17	0.20	-0.17	0.33	0.52	-0.23	0.97
ram	0.16	0.24	0.21	0.21	0.12	0.21	0.25	0.03	0.17	0.26	0.17	0.49	0.23	0.89	1	0.47	0.17	0.23	0.31	0.68	0.92
sc_h	-0.52	-0.02	0.13	0.20	-0.02	0.18	0.16	-0.02	0.37	0.18	0.18	0.17	0.34	0.97	1	1	0.18	0.22	0.53	0.36	0.84
sc_w	-0.72	-0.53	0.13	0.22	-0.37	0.32	0.20	0.09	0.36	0.21	0.15	0.19	0.24	0.97	0.27	1	1	0.78	0.31	0.73	0.97
talk_time	-0.56	0.23	0.43	0.23	0.20	0.42	0.25	-0.03	0.24	0.18	0.19	0.54	0.53	0.96	0.18	0.37	0.18	1	0.78	-0.09	0.88
three_g	-0.86	-0.02	-0.01	-0.22	-0.01	-0.37	0.25	0.28	0.32	-0.21	-0.23	0.26	0.78	0.94	0.72	0.31	0.32	0.32	1	-0.54	0.95
touch_screen	-0.56	-0.03	-0.92	-0.33	-0.01	-0.07	-0.36	-0.01	-0.01	-0.76	-0.05	0.23	-0.51	0.84	-0.59	-0.31	-0.34	0.50	0.76	1	0.95
wifi	-0.17	0.70	0.16	0.15	0.50	0.13	0.14	-0.33	0.59	0.19	-0.13	0.35	-0.81	0.83	0.93	0.76	-0.73	-0.03	0.98	-0.71	1

核心发现

通过计算Pearson相关系数，我们发现RAM（运存大小）与价格等级的相关性高达 **0.92**。这是一个极其强烈的信号，意味着手机的运存大小几乎决定了它的市场定位。

对比

其他特征如电池容量（0.20）和屏幕分辨率（0.17）虽然也呈正相关，但其影响远不及RAM。


数据分布初探：“阶梯状”分层预示着未来的挑战

核心洞察

1. 四个价格等级沿着RAM轴呈现出近乎完美的**阶梯状分布**。
2. 然而，各类别之间的边界并非清晰的直线，而是存在**交织和重叠的模糊区域**。

预示

这种形态对于擅长正交切割的决策树模型非常友好，但对于试图寻找单一全局超平面的SVM来说，将构成严峻挑战。



“做减法”的智慧：用ANOVA F检验筛选出10个黄金特征


预处理流程

1. **完整性检测**：数据集无缺失值。
2. **数据标准化**：对所有连续特征采用 **Z-score 标准化**，消除量纲影响。这对基于距离的KNN和SVM至关重要。
3. **特征选择**：采用基于**ANOVA F-value**的`SelectKBest`方法，筛选出与价格等级区分度最高的10个特征。


关键成果

特征选择使随机森林和KNN的准确率提升了 **6%** 以上，证明了剔除噪声特征的巨大价值。

ANOVA F-scores for Top 10 Features




三大流派的代表：几何间隔(SVM)、邻域投票(KNN)、群体智慧(RF)




支持向量机 (SVM)

寻找能将不同类别以最大几何间隔分开的超平面。一种基于几何的分类器。



K-近邻 (KNN)

通过测量与最近的K个邻居的距离并进行投票来决定类别。一种基于实例的非参数方法。




随机森林 (RF)

构建多棵决策树，通过集体的投票做出最终决策。一种基于规则的集成学习方法。

最终裁决：随机森林大获全胜，SVM意外垫底

模型准确率对比（5折交叉验证）



核心问题

在同样的数据和预处理流程下，模型表现为何存在如此巨大的鸿沟？
尤其是理论上强大的SVM，为何表现最差？

证据一：混淆矩阵揭示SVM的“中间塌陷”


SVM 行为模式

- 在预测两端类别（0：低成本，3：超低成本）时表现优异。
- 在处理中间类别（1：中成本，2：高成本）时彻底迷失，大量样本被错误地归类到相邻类别。


随机森林对比

- 其混淆矩阵热力图在主对角线上数值集中，证明了其在所有类别上稳健、均衡的分类能力。

支持向量机（SVM）混淆矩阵



随机森林（RF）混淆矩阵




证据二： ROC曲线下的无声证词

量化分析

- 随机森林：所有四个类别的ROC曲线都紧贴左上角，AUC（曲线下面积）值接近完美的1.0，表明模型对所有类别都有极高的预测置信度。
- 支持向量机：类别0和3的曲线表现尚可，但**类别1和2的曲线明显塌陷**，更接近随机猜测线（对角线），AUC值显著更低。

结论

这证实了SVM在区分中间价格等级时，其预测能力大打折扣。



破案时刻：致命的“三明治效应”


理论根源

价格等级沿RAM轴线性排列（0 $\rightarrow$ 1 $\rightarrow$ 2 $\rightarrow$ 3）。当SVM采用**One-vs-Rest**策略识别类别1时，它面临的任务是：将正样本 {1} 与负样本集合 {0, 2, 3} 分开。


几何困境

负样本集合 {0, 2, 3} 在特征空间中是**非凸的**（不连续的）。一个线性超平面（就像一把直刀）无法在一次切割中，将处于中间的类别1（馅料）从两边的类别0和2（面包）中完整地分离出来。

RAM轴线性排列的几何挑战



“三明治效应”直观演示




胜利者的武器：决策树的正交切割艺术

随机森林的优势

随机森林的基学习器（决策树）不依赖单一的全局超平面。它通过一系列**正交切割**（Orthogonal Splits）来划分特征空间，生成类似 $(RAM > X) \text{ AND } (RAM < Y)$ 的规则。

解决方案

这相当于在特征轴上进行**两次或多次切割**，可以轻松构建一个能完美包围中间类别（如类别1）的超矩形区域，精准地将“馅料”提取出来。



正交切割成功分离中间类别1



亡羊补牢：如何拯救线性SVM？

诊断

病因是线性模型无法处理数据的非线性（非凸）结构。

处方：升维打击

- 核技巧（Kernel Trick）：使用非线性核函数，如RBF核（高斯核），可以将原始特征空间的数据映射到一个更高维度的空间。
- 效果：在这个高维空间里，原本线性不可分的数据分布被“展开”，从而变得可以用一个超平面来分割。




升维

模型的选择，取决于数据的灵魂



随机森林胜出，实至名归：

其基于规则的**正交切割**能力，完美契合了本数据集的“阶梯状”分层结构。



数据几何形态是关键：

线性SVM的失败源于其无法处理“**三明治效应**”所代表的非凸数据分布。



“没有免费的午餐”原则：

再次验证了不存在普遍最优的算法。最佳模型的选择，永远依赖于对数据内在结构的深刻理解。

真正的任务不是选择算法，而是理解数据

本次实验的价值不仅是找到了一个准确率高达89%的模型。更重要的是，它通过一次深刻的失败分析，揭示了算法原理与数据分布匹配, 的极端重要性。在未来的项目中，我们应当将更多的精力投入到对数据几何形态的探索中，因为这最终将决定我们能否做出最科学的模型选型决策。