

离散时间 Markov 链与自然语言处理中的 N-gram 语言模型

1 引言

Markov 链作为随机过程最为经典且应用最为广泛的基础模型之一，通过引入“无后效性”这一核心假设，即“系统未来的状态仅取决于当前状态，而与过去的历史状态无关”，极大地简化了对复杂动态系统的描述与计算，成为处理离散序列数据的强有力工具。

自然语言处理（NLP）中，对文本序列的建模一直是核心任务。语言本质上是一个随时间推移而生成的离散符号序列，其词与词之间存在着紧密的统计依赖关系。早期的 N-gram 模型，正是基于马尔可夫链的理论框架构建而成的。通过将自然语言生成过程抽象为，N 离散参数、离散状态的随机游走-gram 模型成功地解决了文本概率计算、下一个词预测等基础问题，为后续更复杂的深度学习语言模型奠定了坚实的概率论基础。

因此，在本文中我们将从随机过程的理论出发，系统探讨离散时间马尔可夫链在 N-gram 语言模型中的应用。

2 离散时间 Markov 链的数学模型

2.1 核心定义与状态空间

我们将离散时间 Markov 链视为一类参数离散、状态空间离散的随机过程。

设随机序列 $\{X(n); n \geq 0\}$ 的状态空间为 S （离散），参数集为 $T = \{0, 1, 2, \dots\} = N_0$ 。若对于任意的 $n \in N_0$ ，以及任意的状态 $i_0, i_1, \dots, i_{n+1} \in S$ ，只要条件概率 $P\{X(0) = i_0, X(1) = i_1, \dots, X(n) = i_n\} > 0$ 成立，就有如下等式：

$$\begin{aligned} P\{X(n+1) = i_{n+1} \mid X(0) = i_0, X(1) = i_1, \dots, X(n) = i_n\} \\ = P\{X(n+1) = i_{n+1} \mid X(n) = i_n\} \end{aligned}$$

满足上述条件的随机序列 $\{X(n); n \geq 0\}$ 被称为 Markov 链，简称 Markov 链。

这个等式表明，系统在 $n+1$ 时刻的状态（未来的状态）仅取决于其在 n 时刻的状态（现在的状态），而与 n 时刻之前的历史状态无关。这个特性被称为 Markov 性 or 无后效性。

2.2 关键假设

2.2.1 参数与状态的离散性假设

这是离散时间 Markov 链模型构建的基础前提。

- 参数离散：时间参数取值于非负整数集 $T = N_0$ 。在实际应用中，这对应于离散的观测时刻或序列索引（如句子中的词序）。
- 状态离散：状态空间 S 是有限集 $S = \{1, 2, \dots, n\}$ 或可列集 $S = \{1, 2, \dots\}$ 。这意味着随机变量 $X(n)$ 只能取离散的数值，而非连续值。

2.2.2 Markov 性假设

Markov 性即无后效性。如上述 Markov 链的定义所刻画的，我们假设随机过程将来的状态只与现在的状态有关，而与过去无关。这将对复杂现实系统的各种历史依赖关系做出极大的简化。

2.2.3 时齐性假设

在实际应用中，我们往往假设 Markov 链的转移概率不随时间变化。

设 Markov 链 $\{X(n); n \geq 0\}$ 的状态空间为 S 。若对于任意 $i, j \in S$ ，Markov 链在 n 时刻的一步转移概率 $P\{X(n+1) = j | X(n) = i\} \triangleq p_{ij}(n)$ 满足：

$$P\{X(n+1) = j | X(n) = i\} \triangleq p_{ij}(n) \equiv p_{ij}$$

即上式右边与时刻 n 无关，则称此 Markov 链为**齐次（或时齐的）Markov 链**。

这一假设意味着 Markov 链系统内部的演化规则是稳定的，不会随时间推移而改变。

2.3 数学表达形式

在满足上述假设的基础上，齐次马尔可夫链可以通过以下数学形式进行完备描述。

2.3.1 一步转移概率矩阵

对于齐次 Markov 链，我们可以定义转移概率矩阵 P 。矩阵中的元素 p_{ij} 代表从状态 i 转移到状态 j 的概率。记 $P = (p_{ij})$ ，称矩阵 P 为齐次 Markov 链的一步转移概率矩阵。

$$P = \begin{pmatrix} p_{11} & p_{12} & \cdots \\ p_{21} & p_{22} & \cdots \\ \cdots & \cdots & \ddots \end{pmatrix}$$

根据概率的定义，该矩阵满足以下性质：

1. 非负性： $p_{ij} \geq 0, i, j \in S$
2. 规范性： $\sum_{j \in S} p_{ij} = 1, i \in S$

若状态空间是有限的（设状态数为 n ），则一步转移矩阵 P 是一个 n 阶方阵；若状态是无限可列的，则 P 是形式上的无穷维矩阵。

2.3.2 初始分布

除了转移规则，确定一个 Markov 链还需要系统的初始状态信息。记 $\pi(0)$ 为 Markov 链的初始分布： $\pi_i(0) = P\{X(0) = i\}, i \in S$

只要得到了 Markov 链的一步转移概率矩阵 P 及初始分布 $\pi(0)$ ，就可以获得 Markov 链的任意前 $n + 1$ 维的联合分布：

$$P\{X(0) = i_0, X(1) = i_1, \dots, X(n) = i_n\} = p_{i_0}(0)p_{i_0 i_1}p_{i_1 i_2} \cdots p_{i_{n-1} i_n}$$

这表明 $(P, \pi(0))$ 构成了齐次 Markov 链的完整数学描述。

2.4 核心特征

2.4.1 C-K 方程

对于 m 步转移概率 $p_{ij}^{(m)} = P\{X(n+m) = j \mid X(n) = i\}$ ，存在著名的切普曼—柯尔莫哥洛夫（C-K）方程。对于齐次 Markov 链，C-K 方程可以写成转移概率矩阵乘法的形式：

$$P^{(m+r)} = P^{(m)}P^{(r)}$$

由此可推出 m 步转移矩阵即为一步转移矩阵的 m 次幂：

$$P^{(m)} = P^{(m-1)}P^{(1)} = \dots = (P)^m = P^m$$

该特征揭示了 Markov 链长时段的转移行为完全可以通过短时段（一步）的转移规律迭代得出。

2.4.2 极限性态与平稳分布

当时间趋于无穷时，Markov 链的状态分布往往表现出某种稳定性。

定义：若存在一个概率分布 $\pi = (\pi_1, \pi_2, \dots)$ ，满足：

$$\pi = \pi P$$

即 $\pi_j = \sum_{i \in S} \pi_i p_{ij}$ ，则称 π 为该 Markov 链的平稳分布。

根据遍历定理，对于不可约、非周期且正常返的遍历链，无论初始分布如何，当 $n \rightarrow \infty$ 时，系统处于各状态的概率将收敛于平稳分布 π 。这一特征保证了系统在长期运行下的统计规律是可预测且稳定的。

3 应用场景分析——NLP 中的 N-gram 语言模型

自然语言处理（NLP）旨在让计算机理解和生成人类语言。在深度学习流行之前，统计语言模型是该领域的基石，而其中最经典、应用最广泛的 N-gram 模型，本质上就是离散时间马尔可夫链在文本序列建模中的直接应用。

3.1 场景背景与核心问题

自然语言可以被看作是由字、词或字符组成的时间序列。在机器翻译、语音识别、拼写纠正及输入法联想等任务中，核心挑战往往归结为两个概率问题：

1. 句子概率评估：给定一个词序列 $W = (w_1, w_2, \dots, w_n)$ ，判断它作为一个自然语言句子出现的可能性大小 $P(W)$ 。例如，语音识别系统需要判断用户说的是“南京市长江大桥”（高概率）还是“南京市长加薪大桥”（低概率）。
2. 下一个词预测：给定前 $n - 1$ 个词的历史序列 $(w_1, \dots, w_{n-1})$ ，预测第 n 个词 w_n 出现的条件概率 $P(w_n | w_1, \dots, w_{n-1})$ 。

根据概率论中的链式法则，一个句子的联合概率可以展开为：

$$P(w_1, w_2, \dots, w_n) = P(w_1) \cdot P(w_2 | w_1) \cdot P(w_3 | w_1, w_2) \cdots P(w_n | w_1, \dots, w_{n-1})$$

在实际应用中，随着句子长度 n 的增加，条件概率 $P(w_n | w_1, \dots, w_{n-1})$ 的参数空间呈指数级爆炸，且极易面临数据稀疏问题（即很多长序列在训练语料中从未出现过）。为了解决这一计算难题，必须引入数学模型对历史依赖关系进行简化。

3.2 随机过程在语言模型中的具体表现

若将自然语言的生成过程看作是一个随机系统的动态演化，我们可以将 N-gram 语言模型精准地映射到离散时间 Markov 链 $\{X(n), n \in T\}$ 的框架中。

1. 参数集（时间）的映射：随机过程中的参数 n 在此不代表物理时间，而是代表词在句子中的位置索引。

$$T = \{1, 2, 3, \dots\}$$

即 $X(1)$ 代表句子的第 1 个词，以此类推。这是一个典型的离散参数过程。

2. 状态空间的映射：

随机变量 $X(n)$ 的取值范围即为词汇表。

$$S = \{v_1, v_2, \dots, v_{|V|}\}$$

其中 v_i 表具体的词（如“我”、“是”、“AI”等）。状态空间 S 是离散且有限的。

3. 状态转移的映射：

从 $X(n) = w_i$ 到 $X(n + 1) = w_j$ 的变化，代表了文本生成中从“当前词”到“下一个词”的跳转。其统计规律即对应了随机过程中的转移概率。

3.3 模型与场景的适配性

离散时间马尔可夫链之所以适合拟合 N-gram 语言模型场景，主要基于语言数据的以下统计特性：

1. **局部依赖性**：在自然语言中，词与词之间的搭配关系往往具有局部性。例如，动词后面紧跟名词（如“吃-苹果”），形容词修饰名词（如“美丽的-风景”）。这种“当前词的选择主要受最近几个词影响”的特性，与 Markov 链的无后效性假设高度契合。
2. **统计规律的稳定性**：尽管语言环境千变万化，但在特定的语料库（如新闻语料、医学文献）中，词汇之间的搭配习惯是相对稳定的。例如，“人工智能”后接“技术”的概率在整个语料中大致保持不变。这为引入时齐性假设提供了现实依据，使得我们可以用一个固定的转移矩阵来描述语言规律。

3.4 基于 Markov 链的 N-gram 模型构建

基于上述分析，我们可以利用 Markov 链的理论来构建二元 N-gram 模型（Bigram）。

根据我们前文所说的 Markov 性假设，我们假设一个词出现的概率仅依赖于它前面的一个词：

$$P(w_n | w_1, w_2, \dots, w_{n-1}) \approx P(w_n | w_{n-1})$$

此时，N-gram 模型中的核心参数——条件概率 $P(w_n = j | w_{n-1} = i)$ ，直接对应了马氏链中的一步转移概率 p_{ij} ：

$$p_{ij} = P\{X(n) = j | X(n-1) = i\}$$

该转移概率矩阵 P 以通过对大规模语料库的统计，利用最大似然估计获得：

$$\hat{p}_{ij} = \frac{\text{Count}(w_i, w_j)}{\text{Count}(w_i)}$$

其中， $\text{Count}(w_i, w_j)$ 是词对 (i, j) 在语料中共同出现的次数， $\text{Count}(w_i)$ 是词 i 出现的总次数。

对于更高阶的 **Trigram（三元模型）**，即假设 $P(w_n | w_{n-1}, w_{n-2})$ ，这在理论上可以视为一个二阶马尔可夫链。或者，通过重定义状态空间（将连续两个词 (w_{n-1}, w_n) 视为一个状态），它依然可以转化为一阶马尔可夫链进行处理。

综上所述，N-gram 语言模型本质上就是利用马尔可夫链的转移矩阵来近似复杂的语言概率分布，从而实现对自然语言序列的可计算建模。

4 模型合理性与局限性分析

4.1 合理性

4.1.1 局部依赖捕捉

自然语言具有显著的“短程句法约束”特性。在句子生成过程中，词语的选择往往受到其相邻词语的强力约束。例如，在短语“人工智能”中，“智能”出现的概率极度依赖于前一个词“人工”。这与 Markov 链的无后效性假设高度契合。一阶马尔可夫链（Bigram）通过转移概率 $p_{ij} = P(w_j | w_i)$ 精准地量化了这种相邻词之间的搭配强度。对于大多数语法结构（如动宾搭配、偏正短语），这种基于“当前状态决定下一状态”的机制足以捕捉到核心的语义关联，从而生成通顺的短文本。

4.1.2 计算的可行性

根据我们在 2.3.2 节中的分析，齐次马尔可夫链完全由一步转移概率矩阵 P 和初始分布 $\pi(0)$ 决定。在自然语言处理工程中，这意味着——模型的训练过程可以简化为对语料库的词频统计。相比于需要复杂迭代优化的神经网络模型，基于马尔可夫链的 N-gram 模型具有极高的计算效率：

- 训练简单：参数估计通过最大似然估计（MLE）直接完成，即 $\hat{p}_{ij} \approx \frac{c(w_i w_j)}{c(w_i)}$
- 推理迅速：预测下一个词或计算句子概率仅涉及简单的查表操作和乘法运算。

相比于全历史依赖模型，Markov 模型将参数空间从指数级 $O(|V|^L)$ 压缩到了多项式级 $O(|V|^2)$ 。

4.1.3 宏观统计的稳定性——平稳分布与 Zipf 定律

我们在 2.4.2 节指出，对于一个遍历的马尔可夫链，当时间 $n \rightarrow \infty$ 时，状态分布收敛于平稳分布 π ，满足 $\pi = \pi P$ 。

在自然语言中，这一理论有着深刻的现实投射。语言学统计发现，自然语言的词频分布服从 Zipf 定律（Zipf's Law）：在足够大的语料库中，词汇的使用频率呈现出极其稳定的分布规律。这种宏观上的统计稳定性，暗示了语言生成过程在长期演化下确实达到了某种“统计平衡态”。这意味着，Markov 链不仅在微观上拟合了相邻词的概率，在宏观上，其稳态分布也能自发地逼近人类语言的词频统计规律。这种理论上的一致性有力地支持了用 Markov 过程建模语言的合理性。

4.2 局限性

4.2.1 长距离依赖丢失

马尔可夫性假设是该模型最大的软肋。它强制切断了历史信息，认为 $X(n+1)$ 仅与 $X(n)$ 有关。然而，自然语言中存在大量的长距离依赖。例如一个句子：“The apples on the table by the window which I bought yesterday are red.” 句末谓语“are”的选择取决于句首的主语“apples”（复数），中间跨越了十几个词。对于 Bigram（一阶 Markov 链），它只能看到前一个词“yesterday”，从而极大概率会错误地预测为单数谓语“is”。这种信息的“近视”导致模型无法处理复杂的嵌套句式。

4.2.2 数据稀疏与零概率问题

根据定义，转移矩阵 P 中的元素 p_{ij} 必须基于统计获得。如果词对 (w_i, w_j) 在训练语料中从未出现，则 $p_{ij} = 0$ 。在马尔可夫链理论中，转移概率为 0 意味着该路径不可达。但在人类自然语言中，未见过不代表不可能。只要测试集中出现一个未登录的搭配，整个句子的联合概率就会因连乘而变成 0。为了修正这一理论缺陷，工程上必须引入平滑技术（如拉普拉斯平滑），这本质上是对纯粹马尔可夫估计的一种贝叶斯修正。

4.2.3 状态空间爆炸

理论上，为了缓解长距离依赖问题，可以提高马氏链的阶数（例如使用 4-gram 或 5-gram）。但根据课件中离散状态空间的定义，若词表大小为 $|V|$ ，则 k 阶马尔可夫链的状态空间大小为 $|V|^k$ 。这是一个指数级增长的数值。当 $|V| = 10^5$ 时，即便只是 Trigram（二阶马氏链），参数空间也高达 10^{15} 量级。这不仅导致存储困难，更会导致更加严重的维度灾难，使得没有足够的数据来填满这个稀疏的转移矩阵。

4.2.4 时齐性假设的失效

我们在建模时引入了时齐性假设，即认为转移概率 p_{ij} 不随位置 n 变化。但在真实的文本生成中，语言环境往往是非平稳的。

- 话题漂移：例如，一篇文档前半部分讨论“金融”（Bank 代表银行），后半部分讨论“生态”（Bank 代表河岸），词汇的共现概率随上下文语境动态变化。
- 结构变化：文章开头、中间和结尾的句式分布往往不同。

用一个静态的、全局统一的转移矩阵 P 去拟合一个动态变化的、非齐次的语言过程，必然会损失大量的语境信息。

5 总结

离散时间 Markov 链以其数学上的优雅定义和严谨的极限理论，为自然语言处理提供了一个极其重要的初始框架。通过将语言符号序列化为状态转移，N-gram 模型成功地将不可

计算的联合概率问题转化为可统计的条件概率问题，并在局部依赖捕捉和计算效率上达到了实用的平衡。其平稳分布与 Zipf 定律的契合，更是揭示了随机过程与人类语言统计规律之间深刻的内在联系。

尽管随着深度学习技术的发展，基于神经网络的语言模型（如 RNN、Transformer）在处理长距离依赖和语义表征上已展现出更强大的能力，但 Markov 链模型依然是理解序列数据概率特性的基石。理解 Markov 链，不仅是理解一种随机过程模型，更是理解人类如何试图用数学的确定性去捕捉语言不确定性的一次伟大尝试。