



# 随机过程期末大作业汇报

## ——高斯过程回归与股价预测

汇报人：

汇报时间：2024.12.26

# 目录



01

问题背景

02

理论分析

03

实验步骤

04

实验结果



# Part 01

问题背景



# 实验背景及目的

01

本近年来，人工智能和机器学习领域的学者将更多的目光投向了“随机回归模型”，高斯过程回归（Gaussian Processes Regression, GPR）就是其中的典型代表。

股票价格数据最能反映股票市场的波动变化,股价的预测也成为了投资者们一直关注的热门问题，也是 GPR 的一种典型应用，对于股票交易商来说是非常重要的工具。现有的预测模型在短期预测中显示出有效的结果，然而其准确性在长期预测中会下降。

02

本实验旨在深入理解高斯过程回归（GPR）的底层原理，并通过GPR模型对ADBE、ADSK、MSFT、ORCL、SAP、VRSN股票（国外学生研究过的股票，但原始数据太久远，已经找不到）的历史收盘价进行预测，并从平均绝对百分比误差和置信水平两方面对比评估不同模型在不同大小历史数据集上的表现。

# 实验方法

## //


- 从CSV文件中读取股票的历史数据，包括日期和收盘价，确保数据按时间顺序排列并去除货币符号，将收盘价转换为浮点数
- 使用8:2的比例将数据分为训练集和测试集，确保时间序列的顺序性
- 构建GPR模型，选择合适的核函数（如马特恩核和白噪声核），并对训练集进行拟合，生成预测值
- 探讨了使用不同大小的数据集、不同组合的核函数、GPR结合滑动窗口/全局特性方法对模型预测效果的影响，通过计算平均绝对百分比误差和实际值落在预测上下限区间内的概率，评估模型的预测准确性，并绘制训练集、测试集的真实值和预测值，以及预测的不确定性区间，直观展示模型的表现
- 此外，进行了股票涨跌的预测



# Part 02

理论分析

# ● 高斯分布与高斯过程回归



一元高斯分布

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

多元高斯分布

$$N(\mathbf{x} \mid \mu, \Sigma) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x}-\mu)^T \Sigma^{-1}(\mathbf{x}-\mu)\right\}$$

高斯过程

$$p(\mathbf{y}_* \mid X, \mathbf{y}, Z) = \mathcal{N}\left(\hat{\boldsymbol{\mu}}, \hat{\Sigma} + \sigma_n^2 \mathbf{I}\right)$$

$$\hat{\boldsymbol{\mu}} = K(Z, X)(K(X, X) + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}$$

$$\hat{\Sigma} = K(Z, Z) - K(Z, X)(K(X, X) + \sigma_n^2 \mathbf{I})^{-1} K(Z, X)^T$$



## 滑动窗口

滑动窗口通过创建一系列固定长度的子序列（即窗口），每个窗口包含连续的过去 $\text{window\_size}=30$ 个时间点的数据，用以预测紧接着这个窗口之后的一段未来时间的数据值（设定步长 $\text{pred\_steps}$ ）。具体来说，整个原始时间序列数据首先被转换为特征矩阵 $X$ 和目标向量 $y$ ，其中 $X$ 由每个窗口内的历史数据构成，而 $y$ 则是紧接在每个窗口之后的 $\text{pred\_steps}$ 天期间的真实值。

在训练阶段，模型学习到了如何根据过去的 $\text{window\_size}$ 个时间点的数据来预测下一时间段的值。

而在测试阶段，模型采用滚动预测的方式：从测试集的第一个窗口开始，基于之前的历史数据进行预测，随后将实际观测到的新数据加入到已知数据中，用于下一次预测的输入，这一过程持续到遍历完所有测试数据。



# Part 03

实验步骤

# 数据清洗与预处理

01

```
# 读取数据
data1 = pd.read_csv('NVIDIA.csv', parse_dates=['Date'], index_col='Date')
# 检查数据是否已经是按日期升序排列
if not data1.index.is_monotonic_increasing:
    # 如果不是升序排列, 则进行排序
    data1 = data1.sort_index(ascending=True)
# 去除 'Close/Last' 列中的货币符号并转换为浮点数
data1['Close/Last'] = data1['Close/Last'].str.replace(r'[\^\d.]', '', regex=True)
stock1 = data1['Close/Last'].values
```

02

原始数据:

```
ADBE.csv > data
1 Date,Close/Last,Volume,Open,High,Low
2 12/06/2024,$552.96,2964064,$544.15,$554.37,$542.90
3 12/05/2024,$538.22,2629119,$534.42,$540.11,$529.79
4 12/04/2024,$536.49,3307041,$523.02,$541.77,$521.005
5 12/03/2024,$516.26,2119254,$511.04,$516.78,$504.505
6 12/02/2024,$516.20,2007213,$512.85,$518.77,$511.53
7 11/29/2024,$515.93,1450247,$517.65,$517.65,$513.58
8 11/27/2024,$513.68,2324217,$523.21,$525.88,$508.7161
9 11/26/2024,$525.30,2415735,$519.95,$525.76,$516.3601
10 11/25/2024,$518.73,3319992,$519.09,$523.2099,$513.1935
11 11/22/2024,$512.15,2287614,$502.50,$513.37,$502.50
12 11/21/2024,$504.44,2002094,$502.10,$508.57,$493.10
13 11/20/2024,$499.50,1874910,$505.41,$506.36,$494.61
14 11/19/2024,$499.61,1961731,$496.00,$502.41,$495.46
15 11/18/2024,$499.51,2259651,$505.00,$505.51,$497.69
16 11/15/2024,$503.37,4612417,$520.30,$524.4999,$498.81
17 11/14/2024,$529.87,3098800,$530.55,$534.6399,$523.46
18 11/13/2024,$532.50,3470174,$523.79,$539.92,$520.59
19 11/12/2024,$526.42,4125288,$504.39,$528.91,$504.27
20 11/11/2024,$504.48,3536599,$493.60,$507.72,$493.60
21 11/08/2024,$494.68,2856859,$503.83,$505.00,$493.69
```

03

处理后:

|            |         |          |          |          |           |
|------------|---------|----------|----------|----------|-----------|
| 2014-12-09 | 71.565  | 2866736  | \$71.34  | \$71.66  | \$70.68   |
| 2014-12-10 | 69.850  | 2573489  | \$71.56  | \$71.97  | \$69.74   |
| 2014-12-11 | 69.740  | 5081614  | \$70.10  | \$71.14  | \$69.66   |
| 2014-12-12 | 76.020  | 12603700 | \$74.17  | \$77.56  | \$73.71   |
| 2014-12-15 | 73.040  | 9652775  | \$75.66  | \$76.13  | \$72.84   |
| ...        | ...     | ...      | ...      | ...      | ...       |
| 2024-12-02 | 516.200 | 2007213  | \$512.85 | \$518.77 | \$511.53  |
| 2024-12-03 | 516.260 | 2119254  | \$511.04 | \$516.78 | \$504.505 |
| 2024-12-04 | 536.490 | 3307041  | \$523.02 | \$541.77 | \$521.005 |
| 2024-12-05 | 538.220 | 2629119  | \$534.42 | \$540.11 | \$529.79  |
| 2024-12-06 | 552.960 | 2964064  | \$544.15 | \$554.37 | \$542.90  |

05

```
# 标准化数据
scaler_X = StandardScaler()
scaler_y = StandardScaler()

trainX_scaled = scaler_X.fit_transform(trainX)
trainY_scaled = scaler_y.fit_transform(trainY)

testX_scaled = scaler_X.transform(testX)
```

04

```
# 创建滑动窗口数据集
def create_sliding_window(data, window_size, pred_steps=1):
    X, y = [], []
    for i in range(len(data) - window_size - pred_steps + 1):
        # 输入窗口
        window = data[i:(i + window_size)]
        X.append(window)

        # 目标值可以是未来多步预测
        target = data[i + window_size:i + window_size + pred_steps]
        y.append(target)

    return np.array(X), np.array(y)
```

# ● 超参数的估计



在本次实验中，在从指定个随机起点开始寻找核函数超参数的最佳值时，使用了L- BFGS- B优化算法进行模型超参数的估计，这是一种拟牛顿法，通过构建Hessian矩阵的近似来避免直接计算和求逆Hessian矩阵，从而减少每次迭代的计算成本，提高计算效率。



# 核函数选择

01



## Matérn + WhiteKernel

```
# GPR模型: Matern 和 WhiteKernel 组合  
kernel = ConstantKernel() * Matern(length_scale=1.0, nu=1.5) + WhiteKernel(noise_level=1)
```

$$k_{\text{Matern}}(x, x') = \sigma^2 \frac{2^{1-\nu}}{\Gamma(\nu)} \left( \sqrt{2\nu} \frac{|x-x'|}{l} \right)^\nu K_\nu \left( \sqrt{2\nu} \frac{|x-x'|}{l} \right) \quad k_{\text{White}}(x, x') = \sigma_n^2 \delta(x - x')$$

02



## Rational Quadratic \* Periodic + WhiteKernel

```
# GPR模型: Rational Quadratic * Periodic + WhiteKernel  
kernel = ConstantKernel() * RationalQuadratic(length_scale=1.0, alpha=1.0) * ExpSineSquared(length_scale=1.0, periodicity=30) + WhiteKernel(noise_level=1)
```

$$k_{\text{RQ}}(x, x') = \sigma^2 \left( 1 + \frac{(x-x')^2}{2\alpha l^2} \right)^{-\alpha} \quad k_{\text{Per}}(x, x') = \sigma^2 \exp \left( -\frac{2 \sin^2(\pi |x-x'|/p)}{l^2} \right)$$




# Part 04

实验结果




# 以ADBE股票为例——Matern + WhiteKernel


不使用滑动窗口（全局特征）+10年数据




使用滑动窗口+10年数据



不使用滑动窗口+最近1年数据




滑动窗口+最近1年数据






# 以ADBE股票为例——Rational Quadratic \* Periodic + WhiteKernel

全局特征GPR（1年数据）



使用滑动窗口GPR（10年数据）



总而言之，对于大数据集，滑动窗口方法在两种核函数组合下都表现出了显著的优势，能够更好地捕捉时间序列中的短期动态和局部模式，提供更高的预测精度和合理的置信度。特别是Rational Quadratic \* Periodic + WhiteKernel组合在处理具有复杂动态变化的时间序列时表现出色。对于小数据集，全局特征方法（不使用滑动窗口）表现更好，能够捕捉整体趋势，避免过拟合并提供更高的置信度。Matérn + WhiteKernel组合在小数据集上略优于Rational Quadratic \* Periodic + WhiteKernel组合，可能是因为前者对噪声的鲁棒性更强，更适合处理有限的数。

# 预测步长分析

## ADSK


| 预测结果分析: |       |        |
|---------|-------|--------|
| 步骤      | 平均误差  | 区间概率   |
| 1       | 1.43% | 71.31% |
| 2       | 2.05% | 54.42% |
| 3       | 2.53% | 45.31% |
| 4       | 2.92% | 40.48% |
| 5       | 3.29% | 32.44% |
| 总体      | 2.44% | 48.79% |

## MSFT

| 预测结果分析: |       |        |
|---------|-------|--------|
| 步骤      | 平均误差  | 区间概率   |
| 1       | 1.67% | 85.52% |
| 2       | 2.04% | 72.92% |
| 3       | 2.36% | 63.54% |
| 4       | 2.67% | 57.37% |
| 5       | 2.96% | 52.28% |
| 总体      | 2.34% | 66.33% |

将pred\_steps调整为了5，即采用前面30天的数据，对后续五天的收盘价进行预测。对ADSK和MSFT两只股票进行了预测。


预测步长与误差、概率关系分析



随着预测步长的增加，预测准确性下降非常的严重，会极大地影响到模型的性能。这也侧面反映出了滑动窗口的有效性，能够弥补对于长期预测的性能不足。



# 涨跌预测分析



## Classification Report:

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.61      | 0.39   | 0.47     | 227     |
| 1            | 0.61      | 0.79   | 0.69     | 273     |
| accuracy     |           |        | 0.61     | 500     |
| macro avg    | 0.61      | 0.59   | 0.58     | 500     |
| weighted avg | 0.61      | 0.61   | 0.59     | 500     |

涨跌预测准确率: 52.01%

## 涨跌预测分类报告:

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.47      | 0.70   | 0.57     | 166     |
| 1            | 0.61      | 0.37   | 0.46     | 207     |
| accuracy     |           |        | 0.52     | 373     |
| macro avg    | 0.54      | 0.54   | 0.51     | 373     |
| weighted avg | 0.55      | 0.52   | 0.51     | 373     |



## 参考文献

- [1] C.K. I. Williams, C.E. Rasmussen “Gaussian Processes for Regression”
- [2] M.Ebden, " Gaussian Processes for Regression An Quick Introduction".
- [3] H.M.Wallace, “Introduction to Gaussian Process Regression”
- [4] Z. Ghahramani, ” A Tutorial on Gaussian Processes”
- [5] M.T. Farrell, et al, “Gaussian Process Regression Models for Predicting Stock Trends”.
- [6] Long-term Stock Market Forecasting using Gaussian Processes
- [7] J.M, Tomczak, et, al, “Gaussian process regression as a predictive model for Quality-of-Service in Web service systems”
- [8] Y. Altmann, et,al, “Nonlinear spectral unmixing of hyperspectral images using Gaussian processes”.
- [9] H. Topa, et,al, “Gaussian process modelling of multiple short time series”.
- [10] Chuong B. Do, ”Gaussian Processes”
- [11] C.J. Paciorek, ”NONSTATIONARY GAUSSIAN PROCESSES FOR REGRESSION AND SPATIAL MODELING”



# 谢谢大家

汇报人：朱雨夏 纪舜涵 赵元锦

汇报时间：2024.12.26