

高斯过程回归在金融时间序列预测中的理论 基础与实验方案研究

第一部分：引言与随机过程建模范式的演变

1.1 从确定性模型到随机回归模型的范式转移

在金融时间序列分析的历史长河中，预测模型的发展经历了一个从简单确定性结构向复杂随机过程演变的深刻过程。传统的回归分析，无论是其线性形式还是非线性扩展，长久以来一直是量化金融的基石。在标准的线性回归框架下，模型通常被表述为：

$$Y = AX + N$$

其中， Y 是观测变量向量， X 是自变量矩阵， A 是待求解的模型参数矩阵，而 N 代表加性噪声¹。这一模型的本质假设在于，除了观测噪声 N 之外，系统内部的运作机制——即 A 矩阵所代表的线性映射——是确定性的、静态的。即便将模型扩展至非线性领域，采用 $Y = f(X) + N$ 的形式，只要 $f(X)$ 被假定为某种固定的参数化函数（如多项式或神经网络），模型的核心仍然保留了确定性的特征。然而，金融市场的微观结构和宏观动态充满了不确定性、波动聚集性（Volatility Clustering）以及非平稳性（Non-stationarity），这使得确定性模型在捕捉市场本质时显得力不从心。

近年来，人工智能与统计学习领域的学者逐渐将目光投向了“随机回归模型”（Stochastic Regression Models），其中高斯过程回归（Gaussian Process Regression, GPR）作为一种非参数贝叶斯方法，成为了这一范式转移的典型代表¹。GPR 的核心建模思想可以表述为：

$$Y = g(X) + N$$

与传统模型有着本质区别的是，这里的 $g(X)$ 不再是一个固定的函数，而是某个随机过程（Stochastic Process）的一个样本轨道（Sample Path）片段¹。更准确地说， $g(X)$ 是与输入空间 X 紧密关联的多元高斯分布的采样值。这种视角的转换将回归问题从“寻找最佳拟合曲

线”提升到了“寻找函数空间上的概率分布”这一高度。这意味着，模型不仅能够给出一个点预测值，还能提供关于该预测的置信区间（Confidence Interval），即不确定性度量。对于风险敏感的金融投资决策而言，这种对“未知的未知”的量化能力具有不可估量的价值²。

1.2 研究背景与目标

本研究报告基于随机过程课程的大作业要求，旨在深入探讨高斯过程回归在股票价格预测中的应用潜力。我们将结合课程讲义中关于随机过程的基本定义、平稳性理论以及高斯过程的数学性质，系统梳理 GPR 的理论框架¹。同时，通过研读 Farrell 等人关于股票趋势预测的研究⁴以及 Chapados 和 Bengio 关于长期时间序列预测的文献⁶，我们将提炼出针对金融数据的特征工程与核函数设计方法。

最终，本报告将制定一个详尽的实验方案，利用 NASDAQ 市场的真实股票数据，对比不同核函数配置下的预测性能，并探索如何利用 GPR 的概率输出构建风险规避型的交易策略。这不仅是对课程理论知识的综合应用，也是对前沿机器学习技术在量化金融领域落地的一次严谨探索。

第二部分：随机过程与多元高斯分布的理论基础

要深入理解高斯过程回归，必须首先建立扎实的随机过程与多元高斯分布的理论地基。正如课程讲义所强调的，理解多元高斯随机变量是理解高斯过程的关键钥匙¹。

2.1 随机过程的定义与分类

根据课程讲义，随机过程是定义在概率空间 (Ω, Σ, P) 上的一族随机变量 $\{X(t, \omega); t \in T\}$ ，其中 T 是参数集（通常代表时间）， S 是状态空间¹。对于每一个固定的时间点 t ， $X(t, \cdot)$ 是一个随机变量；而对于每一个固定的样本点 ω ， $X(\cdot, \omega)$ 则是一个关于时间 t 的函数，称为样本函数或样本轨道。

在股票预测的语境下，股价序列 P_t 可以被视为一个离散参数、连续状态的随机过程。然而，直接对股价进行建模往往面临困难，因为金融时间序列通常不满足平稳性（Stationarity）要求。讲义中区分了严平稳（Strict-Sense Stationarity, SSS）和宽平稳（Wide-Sense Stationarity, WSS）¹。

- **严平稳 (SSS):** 指过程的任意有限维联合分布不随时间推移而改变。这是一个极强的条件，在实际金融数据中几乎不可能满足。
- **宽平稳 (WSS):** 仅要求一阶矩（均值）为常数，且二阶矩（自相关函数）仅依赖于时间差 $\tau = t_1 - t_2$ 。

即：

$$m_X(t) = \mathbb{E}[X_t] = \mu$$

$$R_X(t_1, t_2) = \mathbb{E}[X_{t_1}X_{t_2}] = R_X(t_1 - t_2)$$

对于高斯过程而言，宽平稳性等价于严平稳性，这是一个极其重要的性质¹。这意味着，如果我们能通过变换（如对数差分）将股价序列转化为近似宽平稳的过程，我们就可以利用高斯过程的强大工具进行建模。

2.2 多元高斯分布的性质

高斯过程可以被定义为：对于任意有限个输入点集合 $\{x_1, \dots, x_n\}$ ，其对应的函数值向量 $\mathbf{f} = [f(x_1), \dots, f(x_n)]^T$ 都服从多元高斯分布¹。因此，掌握多元高斯分布的性质至关重要。

若随机向量 $\mathbf{X} = (X_1, \dots, X_n)^T$ 服从多元高斯分布 $\mathcal{N}(\mu, \Sigma)$ ，其概率密度函数（PDF）由下式给出：

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right)$$

其中 μ 是均值向量， Σ 是协方差矩阵¹。该分布完全由其一阶矩（均值）和二阶矩（协方差）决定。

2.2.1 线性变换的不变性

讲义中强调了一个关键性质：多元高斯分布在线性变换下保持不变。若 $\mathbf{Y} = \mathbf{C}\mathbf{X}$ ，其中 $\mathbf{C}$ 是

任意矩阵，则 Y 仍然服从高斯分布，其均值为 $C\mu$ ，协方差为 $C\Sigma C^T$ ¹。这一性质在 GPR 中对应于对高斯过程进行线性算子操作（如微分、积分或加权求和）后，结果依然是高斯过程，这为构建复杂的金融衍生品模型提供了理论依据。

2.2.2 条件分布与预测

GPR 的预测核心在于高斯分布的条件概率性质。假设我们将变量分为两部分 $X = \begin{bmatrix} X_A \\ X_B \end{bmatrix}$ ，其对应的均值和协方差矩阵分块如下：

$$\mu = \begin{bmatrix} \mu_A \\ \mu_B \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \Sigma_{AA} & \Sigma_{AB} \\ \Sigma_{BA} & \Sigma_{BB} \end{bmatrix}$$

根据讲义¹，给定观测值 $X_B = x_B$ ，部分 X_A 的条件分布 $P(X_A | X_B = x_B)$ 依然是高斯分布，其均值和协方差分别为：

$$\mathbb{E}[X_A | X_B = x_B] = \mu_A + \Sigma_{AB}\Sigma_{BB}^{-1}(x_B - \mu_B)$$

$$\text{Var}(X_A | X_B = x_B) = \Sigma_{AA} - \Sigma_{AB}\Sigma_{BB}^{-1}\Sigma_{BA}$$

这两个公式构成了高斯过程回归的灵魂。条件均值 $\mathbb{E}[X_A | X_B = x_B]$ 实际上是均方误差意义下的最优估计量（对于高斯分布，最优线性估计与最优非线性估计重合），它给出了我们对未知股价的“最佳猜测”；而条件方差 $\text{Var}(X_A | X_B = x_B)$ 则给出了预测的不确定性量化，这在金融风险管理中对应着“预测置信度”¹。

2.3 高斯过程的定义与规范

基于上述基础，我们可以正式定义高斯过程。一个高斯过程 $f(x)$ 是由其均值函数 $m(x)$ 和协方差函数（核函数） $k(x, x')$ 唯一确定的随机过程⁶：

$$m(x) = \mathbb{E}[f(x)]$$

$$k(x, x') = \mathbb{E}[(f(x) - m(x))(f(x') - m(x')))]$$

记作 $f(x) \sim \mathcal{GP}(m(x), k(x, x'))$ 。在实际应用中，为了简化计算，通常将先验均值函数设为零 ($m(x) = 0$)，但这要求我们对数据进行中心化预处理。协方差函数 $k(x, x')$ 则编码了我们要学习的函数的所有结构特征——平滑性、周期性、趋势性等。它是连接观测数据点之间关系的纽带，决定了已知数据点如何影响对未知点的预测⁸。

第三部分：高斯过程回归的核心机制

在确立了理论基础后，我们需要深入剖析 GPR 作为一个机器学习算法是如何运作的。这不仅涉及数学推导，还包括模型选择 (Model Selection) 和超参数优化 (Hyperparameter Optimization) 的关键步骤。

3.1 贝叶斯推断框架

GPR 是一种典型的非参数贝叶斯方法。不同于参数化模型（如线性回归或神经网络）通过确定的权重参数来拟合数据，GPR 直接在函数空间上定义先验分布，并利用贝叶斯规则在观测数据的基础上更新为后验分布。

假设我们有一组训练数据 $\mathcal{D} = \{(x_i, y_i) \mid i=1, \dots, N\}$ ，其中 y_i 是受噪声污染的观测值：

$$y_i = f(x_i) + \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, \sigma_n^2)$$

我们希望预测新的输入 x_* 对应的函数值 f_* 。根据高斯过程的定义，观测向量

$\mathbf{y}$ 和测试点目标值 f_* 的联合分布是一个多元高斯分布：

$$\begin{bmatrix} \mathbf{y} \\ f_* \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{0} \\ 0 \end{bmatrix}, \begin{bmatrix} K(X, X) + \sigma_n^2 I & K(X, x_*) \\ K(x_*, X) & k(x_*, x_*) \end{bmatrix} \right)$$

其中， $K(X, X)$ 是训练数据点之间的协方差矩阵 (Gram Matrix)， $K(X, x_*)$ 是训练点与测试点之间的协方差向量。利用前述的多元高斯条件分布公式，我们可以直接写出 f_* 的后验分布：

$$\mathbf{f}_* | X, \mathbf{y}, \mathbf{x}_* \sim \mathcal{N}(\bar{\mathbf{f}}_*, \mathbf{V}[\mathbf{f}_*])$$

$$\bar{\mathbf{f}}_* = K(\mathbf{x}_*, X) [K(X, X) + \sigma_n^2 \mathbf{I}]^{-1} \mathbf{y}$$

$$\mathbf{V}[\mathbf{f}_*] = k(\mathbf{x}_*, \mathbf{x}_*) - K(\mathbf{x}_*, X) [K(X, X) + \sigma_n^2 \mathbf{I}]^{-1} K(X, \mathbf{x}_*)$$

这两个方程是 GPR 进行股票预测的操作指南。 $\bar{\mathbf{f}}_*$ 提供了对未来股价（或收益率）的预测值，而 $\mathbf{V}[\mathbf{f}_*]$ 则量化了该预测的风险。当测试点 $\mathbf{x}_*$ 远离训练数据 X 时，协方差项 $K(\mathbf{x}_*, X)$ 趋近于 0，预测方差将回归到先验方差 $k(\mathbf{x}_*, \mathbf{x}_*)$ ，这体现了模型在缺乏数据区域的“认知不确定性”（Epistemic Uncertainty）³。

3.2 核函数：模型的归纳偏置

核函数 $k(x, x')$ 是 GPR 的核心，它决定了生成函数的性质。选择不同的核函数实际上是在向模型注入不同的归纳偏置（Inductive Bias）。

1. 径向基函数 (RBF) / 平方指数 (SE) 核：

$$k_{\text{RBF}}(x, x') = \sigma_f^2 \exp\left(-\frac{|x - x'|^2}{2\ell^2}\right)$$

这是最常用的核，假设函数是无限可微的（极其平滑）。参数 ℓ （长度尺度）控制函数的波动频率， σ_f^2 控制波动幅度。虽然流行，但对于充满噪声和突变的股票价格，RBF 往往过于平滑，可能无法捕捉高频抖动⁸。

2. Matérn 核：

Matérn 核引入了一个参数 ν 来控制函数的平滑度（可微次数）。当 $\nu \rightarrow \infty$ 时，它收敛于 RBF 核。在金融建模中，Matérn 3/2 或 Matérn 5/2 通常比 RBF 表现更好，因为它们允许样本轨道更加粗糙，更符合物理过程和金融市场的随机游走特性¹⁰。

3. 有理二次 (Rational Quadratic, RQ) 核：

$$k_{\text{RQ}}(r) = \sigma^2 \left(1 + \frac{r^2}{2\alpha\ell^2}\right)^{-\alpha}$$

可以看作是不同长度尺度 RBF 核的无穷加权和。它非常适合多尺度数据，即数据中同时包含长期趋势和短期波动的情况，这与股票市场的特征高度契合 8。

4. 周期 (Periodic) 核:

$$k_{\text{Per}}(r) = \sigma^2 \exp\left(-\frac{2\sin^2(\pi r / p)}{\ell^2}\right)$$

用于捕捉重复模式。在股票市场中，可能存在季节性效应（如“一月效应”）或基于财报周期的波动模式 12。

5. 谱混合 (Spectral Mixture, SM) 核:

这是一个高级核函数，基于 Bochner 定理。Bochner 定理指出，任何平稳核函数都是正谱密度 (Spectral Density) 的傅里叶变换 13。SM 核通过将谱密度建模为高斯混合模型，能够自动发现数据中复杂的准周期模式，而无需人工指定周期 p 。这对于捕捉金融时间序列中隐含的、非显式的周期性规律具有极大的潜力 15。

3.3 超参数优化与对数边际似然

GPR 的性能高度依赖于核函数的超参数 θ （如长度尺度 ℓ 、噪声方差 σ_n^2 等）。与神经网络通过最小化损失函数来训练不同，GPR 通常通过最大化**对数边际似然 (Log Marginal Likelihood, LML) **来进行模型选择 16:

$$\log p(\mathbf{y}|X, \theta) = -\frac{1}{2} \mathbf{y}^T (K_\theta + \sigma_n^2 I)^{-1} \mathbf{y} - \frac{1}{2} \log |K_\theta + \sigma_n^2 I| - \frac{n}{2} \log 2\pi$$

这个公式包含三个部分:

- 数据拟合项 (Data Fit) :** $-\frac{1}{2} \mathbf{y}^T K^{-1} \mathbf{y}$, 是唯一的正项，鼓励模型拟合数据。
- 复杂度惩罚项 (Complexity Penalty) :** $-\frac{1}{2} \log |K|$, 仅取决于协方差矩阵的行列式。模型越复杂（相关性越强），该项惩罚越大。
- 常数项:** $-\frac{n}{2} \log 2\pi$ 。

这种基于 LML 的优化机制使得 GPR 具有自动的“奥卡姆剃刀”效应 (Occam's Razor)，能够在拟合精度和模型复杂度之间自动寻找平衡，从而在一定程度上避免了过拟合，这对于信噪比极低的金融数据尤为重要。

第四部分：文献综述与方法论整合

为了制定科学的实验方案，我们必须深入分析题目要求的参考文献，特别是 Farrell 等人和 Chapados & Bengio 的工作，从中汲取经验教训。

4.1 Farrell 等人的股票趋势预测研究

Farrell 和 Correa 的研究《Gaussian Process Regression Models for Predicting Stock Trends》直接针对股票预测问题。他们利用 GPR 预测股票是否会上涨或下跌，并量化变化的幅度。

- **输入特征：**他们不仅使用了前一天的收盘价，还构建了基于价格趋势的度量指标⁴。
- **核函数比较：**他们的实验对比了 RBF 核、Matérn 核和 RQ 核。结果表明，虽然 RQ 核理论上能捕捉多尺度变化，但在有限且高噪的金融数据上，较简单的 RBF 或 Matérn 核往往表现出更强的鲁棒性，因为它们更不容易过拟合噪音⁵。
- **数据窗口：**一个关键发现是，增加训练数据的历史长度并不总能提高短期预测的准确性。由于市场体制 (Market Regime) 的非平稳性，过于久远的历史数据可能对当前的市场动态没有指导意义，甚至引入干扰。这提示我们在实验设计中应采用**滑动窗口 (Sliding Window) **策略⁵。

4.2 Chapados 与 Bengio 的长期预测方法

Chapados 和 Bengio 在《Long-term Stock Market Forecasting using Gaussian Processes》中提出了一种创新的“函数式数据分析”视角。

- **函数式表示 (Functional Representation)：**传统的预测模型将时间序列视为一个连续的长向量 $y_1, y_2, \dots, y_t$ 。Chapados 提出将时间序列分割成若干段（例如，每年的价格曲线），将每一段视为一个函数样本 $f_i(t)$ 。这样，预测明年的股价就变成了根据过去几年的“形状”分布来推断新的函数形状⁶。

- **增强输入空间：**这种方法允许模型学习季节性模式（如年度周期）和长期结构。对于大宗商品等具有强周期性的资产，这种方法效果显著。虽然股票不像农产品那样有严格的生长周期，但季度财报、年度税务等事件赋予了股市某种程度的年度节奏，这种函数式视角值得借鉴。

4.3 综合启示

结合上述文献和讲义，我们可以得出构建股票预测 GPR 模型的几个关键原则：

1. **非平稳性处理：**必须对原始价格进行变换（如取对数收益率），使其满足宽平稳假设，或者使用能够处理非平稳性的复杂核（如 Spectral Mixture）。
2. **输入特征多样化：**仅依赖滞后的价格数据（AR 模型）是不够的。应引入技术指标（如 MACD, RSI）作为额外的输入维度，利用多元高斯分布处理高维输入的能力¹⁸。
3. **动态适应：**由于金融市场的统计特性随时间变化（Regime Shifts），必须采用滚动窗口（Rolling Window）进行训练和预测，定期更新超参数。

第五部分：特征工程与数据预处理方案

高质量的输入数据是模型成功的先决条件。针对高斯过程对平稳性的要求以及金融数据的特性，我们设计如下的数据处理流程。

5.1 数据获取与清洗

数据源：选取 NASDAQ 市场中具有代表性的科技股（如 AAPL, MSFT, AMZN, GOOG）以及指数 ETF（如 QQQ）。数据范围选择过去 5-10 年，覆盖牛市、熊市及震荡市，以检验模型的泛化能力。

清洗：处理缺失值（使用线性插值或前值填充），调整除权除息（Split-adjusted prices）。

5.2 平稳性变换：对数收益率

原始股价 P_t 通常呈现几何布朗运动特征，具有随机游走性质，是非平稳的（均值和方差随时间变化）。直接将 P_t 作为 GPR 的目标变量 y 会违反平稳核函数的假设。因此，我们采用**对数收益率（Log>Returns）**作为预测目标²⁰：

$$r_t = \ln(P_t) - \ln(P_{t-1}) = \ln\left(\frac{P_t}{P_{t-1}}\right)$$

对数收益率具有以下优点：

1. 统计特性更接近平稳过程（虽然仍存在波动率聚集，但均值回复特性更好）。
2. 具有可加性，方便多周期计算。
3. 值域通常在 $[-0.1, 0.1]$ 之间，有利于数值计算的稳定性。

5.3 输入向量构建 (\$X\$)

我们将构建一个多维特征向量 $\mathbf{x}_t$ 来预测 r_{t+1} 。不仅仅使用时间 t 作为输入，而是构建一个自回归与技术指标结合的特征空间，利用 GPR 的回归能力（Regression）而非简单的插值（Interpolation）。

特征向量 $\mathbf{x}_t$ 包括：

1. **滞后收益率 (Lagged Returns):** $r_t, r_{t-1}, r_{t-2}, r_{t-3}, r_{t-4}$ 。这捕捉了短期的时间依赖性（周级别）。
2. **移动平均收敛散度 (MACD):** 这是一个动量指标，反映了两条移动平均线之间的差异。

$$\text{MACD} = \text{EMA}_{12}(P) - \text{EMA}_{26}(P)$$

$$\text{Signal} = \text{EMA}_9(\text{MACD})$$

输入特征可以是 MACD 值及其 Histogram（差值），用于捕捉趋势变化的信号¹⁸。

3. **相对强弱指数 (RSI):** 一个震荡指标，取值 0-100，用于判断超买或超卖状态。GPR 可以学习 RSI 高企时回报率均值回复的非线性关系¹⁸。
4. **历史波动率 (Volatility):** 过去 20 天收益率的标准差。这对于让 GPR 的预测方差（不确定性）具有异方差性（Heteroscedasticity）至关重要。如果输入包含波动率信息，GPR 可以学习到“市场波动大时，预测不确定性也大”的规律²⁰。

所有输入特征必须进行标准化处理（Z-score normalization），即减去均值除以标准差，使其分布接近 $\mathcal{N}(0, 1)$ 。这对于基于距离的核函数（如 RBF）至关重要，否则量纲大的特征将主导核函数的计算。

第六部分：详细实验方案

本节是报告的核心，根据作业要求制定具体的实施步骤。

6.1 实验假设与目标

假设：

- 相比于简单的 RBF 核，组合核（如 Matérn + Periodic）或谱混合核（Spectral Mixture）能够更好地捕捉股票收益率的复杂动态，从而降低预测误差。
- GPR 输出的预测方差 $\mathbb{V}[f_*]$ 与真实的市场风险（如实际波动率）具有相关性，可以用于风险控制。

目标：

- 构建并训练不同核函数的 GPR 模型预测 NASDAQ 个股的次日对数收益率。
- 对比 GPR 与基准模型（如 ARIMA、LSTM）的性能。
- 评估 GPR 预测不确定性的有效性。

6.2 核函数设计策略

我们将对比三种不同复杂度的核函数配置，以此测试“归纳偏置”对预测的影响：

- 模型 A（基准）：RBF 核 + 白噪声核

$$k_A(x, x') = \sigma_f^2 \exp\left(-\frac{|x - x'|^2}{2\ell^2}\right) + \sigma_n^2 \delta_{ii}$$

这是最标准的配置，假设收益率函数是局部平滑的。 σ_n^2 用于吸收不可预测的市场随机噪声。

- 模型 B（结构化）：Matérn 3/2 + 有理二次 (RQ)

$$k_B(x, x') = k_{\text{Matérn3/2}}(x, x') + k_{\text{RQ}}(x, x') + \sigma_n^2 \delta_{ii}$$

- Matérn 3/2 允许过程更加粗糙（只有一次可微），更符合金融数据的“毛刺”特征。
- RQ 核捕捉多尺度的波动（长期趋势叠加短期震荡）。

这种组合旨在模拟市场在不同时间尺度上的行为差异。

- 模型 C（频域发现）：谱混合核 (Spectral Mixture, SM)

$$k_C(\tau) = \sum_{q=1}^Q w_q \exp(-2\pi^2 \tau^T \Sigma_q \tau) \cos(2\pi \mu_q^T \tau)$$

设定分量数 $Q=4$ 。SM 核能够自动从数据中学习隐含的周期和频率成分，而无需像周期核那样人工指定周期 p 。我们期望它能发现诸如“季度效应”或更复杂的市场微观结构周期 13。

6.3 训练与验证协议：滚动窗口 (Rolling Window)

鉴于金融数据的非平稳性（市场规律会随时间漂移）以及 GPR $O(N^3)$ 的计算复杂度，我们将采用**滚动窗口回测 (Rolling Window Backtesting)**策略，这在 Farrell 等人的研究中被证明是有效的⁵。

1. 窗口设置：

- **训练窗口 (Train Window):** 长度 $L = 252$ 天（约一个交易年）。
- **预测步长 (Forecast Horizon):** $H = 1$ 天（次日预测）。
- **再训练频率 (Refit Frequency):** 每隔 $K = 20$ 天（约一个月）重新优化一次超参数。

2. 流程：

- 在时间点 t ，利用 $[t-L, t-1]$ 的数据 $(X_{\text{train}}, \mathbf{y}_{\text{train}})$ 训练 GPR 模型，最大化对数边际似然 (LML) 以获得最优超参数 $\hat{\theta}$ 。
- 利用训练好的模型，输入 x_t （当天的特征），预测 r_{t+1} 的均值 μ_* 和方差 σ_*^2 。
- 窗口向右滑动一天（或 K 天），重复上述过程，直到测试集结束。

3. 优化细节：

- 使用 L-BFGS-B 或 Adam 优化器最大化 LML。

- 由于 LML 尤其是 SM 核的 LML 是非凸的，存在多个局部最优解，我们将在每次重训练时采用**多次随机重启（Random Restarts）**策略（例如 10 次），选择 LML 最大的那一组超参数¹⁶。

6.4 评估指标

不仅关注点预测的准确性，更要关注概率预测的质量。

1. 均方根误差 (RMSE): 衡量点预测 μ_* 与真实值 y_{true} 的平均偏差。

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (\mu_{*,t} - y_{\text{true},t})^2}$$

2. 方向准确率 (Directional Symmetry, DS) / 命中率 (Hit Rate): 衡量模型是否正确预测了涨跌方向。这对交易策略至关重要。

$$\text{DS} = \frac{1}{T} \sum_{t=1}^T \mathbb{I}[\text{sign}(\mu_{*,t}) = \text{sign}(y_{\text{true},t})] \times 100\%$$

其中 $\mathbb{I}$ 是示性函数。如果 DS 显著高于 50%，说明模型具有择时能力²⁴。

3. 负对数预测密度 (Negative Log Predictive Density, NLPD): 这是评估概率预测质量的核心指标。它考察模型是否对其预测不仅准确，而且“诚实”（Confidence calibrated）。如果模型预测错误但方差很小（盲目自信），NLPD 会惩罚得非常重；如果模型预测错误但方差很大（知道自己不确定），惩罚较轻。

$$\text{NLPD} = -\frac{1}{T} \sum_{t=1}^T \log p(y_{\text{true},t} | X, \mathbf{y}, x_t)$$

$$\log p(y_* | \dots) = -\frac{1}{2} \log(2\pi\sigma_{*,t}^2) - \frac{(y_{\text{true},t} - \mu_{*,t})^2}{2\sigma_{*,t}^2}$$

较低的 NLPD 意味着更好的概率预测性能²⁶。

第七部分：预期结果与挑战分析

7.1 预期结果

基于文献分析，我们预期：

- 模型性能：**模型 C (Spectral Mixture) 和模型 B (Structural) 在 RMSE 和 NLPD 指标上应优于基准模型 A (RBF)。这是因为股票市场包含多种频率的波动，简单的 RBF 往往会过度平滑，导致对剧烈波动的反应滞后 (Lag)。
- 不确定性量化：**我们预期会观察到预测方差 σ^2 的**时变性**。在市场剧烈震荡（如财报发布前后或宏观经济事件发生时），GPR 输出的置信区间应当自动变宽。这验证了模型捕捉异方差性的能力。
- 输入特征的影响：**引入技术指标（如 RSI）作为输入，应该能提高方向准确率 (DS)。因为 RSI 蕴含了均值回复的信息，当 RSI 极高时，GPR 可能会学习到下一时刻收益率为负的概率增加。

7.2 计算挑战与应对

GPR 的主要瓶颈是协方差矩阵求逆的 $O(N^3)$ 复杂度。在本实验设计中，我们将训练窗口限制在 252 天，对于这个规模 ($N=252$)，现代 CPU/GPU 可以毫秒级完成计算，因此标准 GPR 是可行的。如果为了追求更长历史记忆而扩大 N （例如 $N > 2000$ ），我们将需要引入**稀疏高斯过程 (Sparse GP)**，通过引入少量的“诱导点” (Inducing Points) 来近似全协方差矩阵，将复杂度降低到 $O(NM^2)$ ，其中 M 是诱导点数量²⁸。

7.3 数值稳定性

在计算 K^{-1} 时，协方差矩阵可能因为特征值差异极大而变得病态 (Ill-conditioned)。为了保证 Cholesky 分解的稳定性，我们需要在对角线上添加一个微小的抖动项 (Jitter)，即 $K + (\sigma_n^2 + \epsilon)I$ ，其中 $\epsilon \approx 10^{-6}$ 。这是一个工程上必不可少的技巧。

第八部分：结论

本研究报告构建了一个完整的基于高斯过程回归的股票预测框架。从随机过程的理论出发，我们确立了以平稳性变换（对数收益率）为基础，以多元高斯分布的条件推断为核心预测机制的方法

论。通过对比 RBF、Matérn、Rational Quadratic 以及 Spectral Mixture 等多种核函数，并结合滑动窗口训练策略，本实验旨在验证 GPR 在捕捉金融时间序列非线性动态及量化预测不确定性方面的独特优势。

相较于传统的“黑箱”模型（如深度神经网络），GPR 的最大价值在于其**可解释的概率输出**。它不仅告诉投资者股价可能是多少，还通过方差告诉投资者这一预测的可靠程度。这种风险感知的特性，使得 GPR 在构建自动化交易策略和风险管理系统中具有重要的应用前景。通过执行本实验方案，我们将能够实证检验这一理论潜力在真实 NASDAQ 市场数据中的表现。

附录：核心数学公式汇总

高斯过程后验分布：

$$\bar{\mathbf{f}}_* = \mathbf{k}_*^T (K + \sigma_n^2 I)^{-1} \mathbf{y}$$

$$\mathbb{V}[\mathbf{f}_*] = k(x_*, x_*) - \mathbf{k}_*^T (K + \sigma_n^2 I)^{-1} \mathbf{k}_*$$

对数边际似然 (LML)：

$$\mathcal{L}(\theta) = -\frac{1}{2} \mathbf{y}^T (K_\theta + \sigma_n^2 I)^{-1} \mathbf{y} - \frac{1}{2} \log |K_\theta + \sigma_n^2 I| - \frac{n}{2} \log 2\pi$$

核函数表达式：

- RBF*: $k(r) = \exp(-r^2 / 2\ell^2)$
- Rational Quadratic*: $k(r) = (1 + \frac{r^2}{2\alpha\ell^2})^{-\alpha}$
- Spectral Mixture*: $k(\tau) = \sum_q w_q \exp(-2\pi^2 \tau^T \Sigma_q \tau) \cos(2\pi \mu_q^T \tau)$

引用的著作

- 5639227.pdf

2. Gaussian Process Regression (GPR) - GeeksforGeeks, 访问时间为 十二月 20, 2025, <https://www.geeksforgeeks.org/machine-learning/gaussian-process-regression-gpr/>
3. Mastering Gaussian Process Regression: A Powerful Tool for Uncertainty-Aware Predictions, 访问时间为 十二月 20, 2025, https://hiya31.medium.com/mastering-gaussian-process-regression-a-powerful-tool-for-uncertainty-aware-predictions-4ae47c513ee7?source=rss-----artificial_intelligence-5
4. Gaussian Process Regression Models for Predicting Stock Trends - Semantic Scholar, 访问时间为 十二月 20, 2025, <https://www.semanticscholar.org/paper/Gaussian-Process-Regression-Models-for-Predicting-Farrell-Correa/dbac5c13367d6e34d764927e4d02b8d1f50cb19f>
5. (PDF) Gaussian Process Regression Models for Predicting Stock Trends - ResearchGate, 访问时间为 十二月 20, 2025, https://www.researchgate.net/publication/249769503_Gaussian_Process_Regression_Models_for_Predicting_Stock_Trends
6. Long-Term Stock Market Forecasting Using Gaussian Processes: Anonymous Author(s), 访问时间为 十二月 20, 2025, <https://www.scribd.com/document/362259659/p5>
7. Stock Market Prediction using Twin Gaussian Process Regression - Moin Nabi, 访问时间为 十二月 20, 2025, <https://moinnabi.github.io/files/stock.pdf>
8. Gaussian Process Kernels. More than just the radial basis... | by Ненавин | TDS Archive, 访问时间为 十二月 20, 2025, <https://medium.com/data-science/gaussian-process-kernels-96bafb4dd63e>
9. Time series forecasting with Gaussian Processes needs priors, 访问时间为 十二月 20, 2025, <https://people.idsia.ch/~zaffalon/papers/2021ecmlpkdd-gps4ts.pdf>
10. Financial Applications of Gaussian Processes and Bayesian Optimization - Amundi Research Center, 访问时间为 十二月 20, 2025, <https://research->

center.amundi.com/files/nuxeo/dl/28a08579-8ebe-4470-a2ea-d8d997a92adc?inline=

11. Discovery of Potent Inhibitors of α -Synuclein Aggregation Using Structure-Based Iterative Learning | bioRxiv, 访问时间为 十二月 20, 2025, <https://www.biorxiv.org/content/10.1101/2021.11.10.468009v3.full-text>
12. Kernel Cookbook - Department of Computer Science, University of Toronto, 访问时间为 十二月 20, 2025, <https://www.cs.toronto.edu/~duvenaud/cookbook/>
13. Marginalised Gaussian Processes with Nested Sampling, 访问时间为 十二月 20, 2025, <https://proceedings.neurips.cc/paper/2021/file/712a67567ec10c52c2b966224cf94d1e-Paper.pdf>
14. Covariance Kernels for Fast Automatic Pattern Discovery and Extrapolation with Gaussian Processes - CMU School of Computer Science, 访问时间为 十二月 20, 2025, <https://www.cs.cmu.edu/~andrewgw/andrewgwthesis.pdf>
15. Multivariate Gaussian Process Regressions of the S&P 500 Equity Index - Medium, 访问时间为 十二月 20, 2025, <https://medium.com/@rodney.greene50/multivariate-gaussian-process-regressions-of-the-s-p-500-equity-index-6784e3875926>
16. 1.7. Gaussian Processes — scikit-learn 1.8.0 documentation, 访问时间为 十二月 20, 2025, https://scikit-learn.org/stable/modules/gaussian_process.html
17. Gaussian Process Regression (GPR) with Noise-Level Estimation - GeeksforGeeks, 访问时间为 十二月 20, 2025, <https://www.geeksforgeeks.org/machine-learning/gaussian-process-regression-gpr-with-noise-level-estimation/>
18. Predicting Short Term Stock Trends using Gaussian Regression - Index of /, 访问时间为 十二月 20, 2025, <https://web.lums.edu.pk/~adnan.khan/quantfin.pdf>
19. Augmented Functional Time Series Representation and Forecasting with Gaussian Processes. | Request PDF - ResearchGate, 访问时间为 十二月 20, 2025,

https://www.researchgate.net/publication/221619353_Augmented_Functional_Time_Series_Representation_and_Forecasting_with_Gaussian_Processes

20. Forecasting Stock Market Volatility with Regime-Switching GARCH-MIDAS: The Role of Geopolitical Risks Mawuli Segnon - University of Pretoria, 访问时间为 十二月 20, 2025,
https://www.up.ac.za/media/shared/61/WP/wp_2022_03.zp214290.pdf
21. An Overview of Gaussian process Regression for Volatility Forecasting - Oxford Man Institute of Quantitative Finance, 访问时间为 十二月 20, 2025,
<https://www.oxford-man.ox.ac.uk/wp-content/uploads/2020/06/An-Overview-of-Gaussian-process-Regression-for.pdf>
22. Financial market prediction under deep learning framework using auto encoder and kernel extreme learning machine | Request PDF - ResearchGate, 访问时间为 十二月 20, 2025,
https://www.researchgate.net/publication/346798658_Financial_market_prediction_under_deep_learning_framework_using_auto_encoder_and_kernel_extreme_learning_machine
23. Ability of Gaussian process regression (GPR) to estimate data noise-level - Scikit-learn, 访问时间为 十二月 20, 2025, https://scikit-learn.org/stable/auto_examples/gaussian_process/plot_gpr_noisy.html
24. Multivariate and Online Prediction of Closing Price Using Kernel Adaptive Filtering - PMC, 访问时间为 十二月 20, 2025,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC8709756/>
25. A bidirectional LSTM model for cryptocurrency prices forecasting, 访问时间为 十二月 20, 2025,
https://login.semead.com.br/25semead/anais/download.php?cod_trabalho=975
26. Scalable Gaussian Process Regression Using Deep Neural Networks - Semantic Scholar, 访问时间为 十二月 20, 2025,
<https://www.semanticscholar.org/paper/Scalable-Gaussian-Process-Regression-Using-Deep-Huang-Zhao/c759c1f4376e322943d8a463064367fcee5f4eb6>

27. A novel hybrid interval prediction framework integrating multiobjective optimization and quantile deep learning for copper price prediction - NIH, 访问时间为 十二月 20, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12540788/>
28. Gaussian Processes and Kernel Methods - MLG Cambridge, 访问时间为 十二月 20, 2025, <https://mlg.eng.cam.ac.uk/research/gp/>
29. Gauss-Legendre Features for Gaussian Process Regression - Journal of Machine Learning Research, 访问时间为 十二月 20, 2025, <https://jmlr.org/papers/volume23/21-0030/21-0030.pdf>